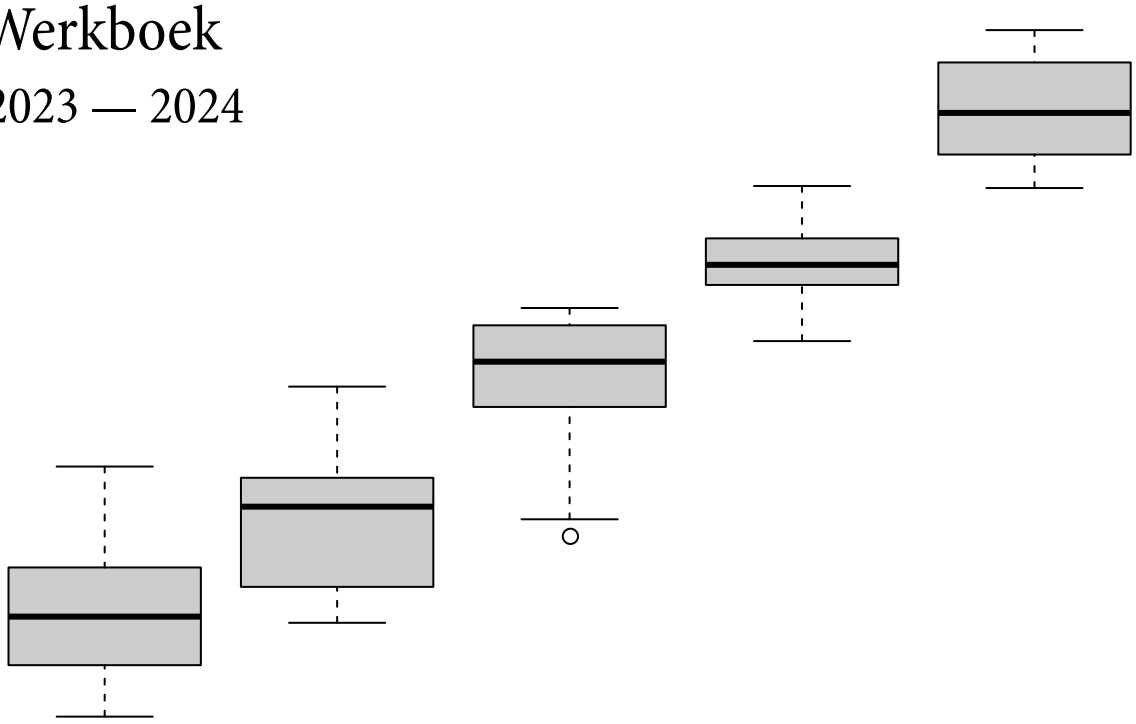
Statistiek

Onderdeel van 'Kwantitatieve Biologie'

Werkboek

2023 — 2024



Rutger Hermsen

Universiteit Utrecht, Departement Biologie, Theoretische Biologie

Inhoudsopgave

Inhoudsopgave **3**

Over dit werkboek **5**

I Werkcolleges 7

Week 1: Beschrijven **9**
1.1 Week 1, werkcollege A 9
1.2 Week 1, werkcollege B 11

Week 2: Schatten **15**
2.1 Week 2, werkcollege A 15
2.2 Week 2, werkcollege B 17

Week 3: Toetsen **21**
3.1 Week 3, werkcollege A 21
3.2 Week 3, werkcollege B 24

Week 4: Relaties **33**
4.1 Week 4 33

Week 5: Het ontwerpen van experimenten & Voorbereiding tentamen **43**

Uitwerkingen van de werkcollegeopgaven **47**

II Computerpractica 59

Computerpracticum 1: Beschrijvende statistiek & t-toetsen **61**

Computerpracticum 2: ANOVA, correlatie & regressie **65**

Over dit werkboek

In dit boek vind je de opgaven van de werkcolleges en computerpractica van het onderdeel Statistiek van het vak 'Kwantitatieve Biologie'. Lees voordat je begint de volgende informatie even door.

Het format van in- en uitvoer van R

In dit boek wordt regelmatig R-code getoond. Een regel R-code ziet er dan als volgt uit:

```
> t.test(x ~ y, data = mijndata)
```

Je ziet dus dat een regel code altijd wordt voorafgegaan door het tekentje >. Bovendien heeft de code een grijze achtergrond.

Ook laten we vaak uitvoer zien die R heeft gegenereerd door één of meerdere regels code uit te voeren. Dat ziet er bijvoorbeeld zo uit:

```
    Two Sample t-test

data:  cholesterol by sex
t = -0.62681, df = 11, p-value = 0.5436
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -6.423378  3.575759
sample estimates:
  mean in group man mean in group vrouw
           224.2429            225.6667
```

Merk op dat een regel uitvoer *niet* met het tekentje > begint en dat het lettertype iets kleiner is.

Notatie

Hieronder, en in de rest van het werkboek, worden opgaven uit het boek van Whitlock & Schluter (W&S) aangegeven in het format [hoofdstuk].[opgavenummer]. Opgave 1.3 uit W&S is dus opgave 3 uit hoofdstuk 1 van Whitlock & Schluter.

Verschillen tussen de 2^e en 3^e editie van W&S

Sommige studenten werken met de 2^e editie van W&S en de anderen met de 3^e editie. Daar waar de nummers van de opgaven tussen beide edities verschillen zal dit worden aangegeven. Dan staat er bijvoorbeeld: "Maak opgave 1.14 (2^e editie) of 1.15 (3^e editie) uit W&S."

Soms wordt ook verwezen naar paginanummers uit de 2^e of 3^e editie. Onhandig is dat hierbij ook soms de specifieke versie of druk van het boek uitmaakt. Lijkt het paginanummer niet te kloppen, vraag dan gewoon even aan je studentassistent en/of medestudenten wat de bedoeling is.

Uitwerkingen

Achter in W&S staan uitwerkingen voor alle *Practice Problems*. De uitwerkingen van alle andere werkcollegeopgaven staan in dit werkboek (p. 47 en verder). Uitwerkingen van de computerpractica worden na

afloop van de computerpractica verstrekt op Blackboard.

Feedback

Het is mogelijk dat je fouten of onduidelijkheden in de tekst zult aantreffen. Zou je die dan aan de docent willen doorgeven? Dan lopen de studenten van volgend jaar hopelijk tegen minder problemen aan dan jij.

Veel succes!

Deel I

Werkcolleges

Week 1: Beschrijven

Voorbereiding

Voor aanvang van ieder werkcollege:

- Bestudeer de relevante hoofdstukken uit Whitlock & Schluter (zie de Studiewijzer op Blackboard).
- Bestudeer de dia's van het hoorcollege.
- Hou een lijst bij met vragen over de stof, zodat je die op het werkcollege kunt stellen.

Onderwerpen

Populatie en (aselecte) steekproef • variabiliteit • typen variabelen • visualisatie van gegevens • maten voor ligging en spreiding.

1.1 Week 1, werkcollege A

Verwerken & Oefenen

{ Onderstaande opgaven zijn bedoeld om je te helpen bij het verwerken van de leerstof en het oefenen van vaardigheden. }

■ **Opgave 1.** Van welk type zijn de volgende variabelen?

a) Het aantal soorten gras dat wordt aangetroffen in een serie plotjes afgezet in een weiland.

b) De onderverdeling van bacteriën in gram-positief en gram-negatief.

c) Embryonale ontwikkelingsstadia (zoals morula, blastula, …).

d) De zuurtegraad (pH) van een oplossing.

■ **Opgave 2.** Een steekproef van $n = 3$ volwassen poezen levert de volgende gewichten op: $Y_1 = 3{,}0\,\text{kg}$, $Y_2 = 3{,}4\,\text{kg}$, $Y_3 = 4{,}2\,\text{kg}$. (Zie uitleg hiernaast.)

Formules in de statistiek bevatten vaak sommatietekens (dus: $\sum$) en indices (de i in Y_i). In deze opgave oefenen we het gebruik daarvan.

a) Bereken $\sum_{i=1}^{3} Y_i$.

b) Leg uit dat het gemiddelde gewicht $\bar{Y}$ kan worden geschreven als

$$\bar{Y} = \frac{\sum_{i=1}^{3} Y_i}{3}.$$

Bereken $\bar{Y}$.

c) Bereken $\sum_{i=2}^{3} Y_i$.

d) Bereken $\sum_{i=1}^{n} Y_i$.

e) Bereken $\sum_{i=1}^{n} Y_i^2$.

f) Bereken $\left(\sum_{i=1}^{n} Y_i\right)^2$.

g) Bereken $\sum_{i=1}^{n} (Y_i - \bar{Y})$.

h) Bereken $\sum_{i=1}^{n} (Y_i - \bar{Y})^2$.

i) Bereken de variantie van de gewichten. Maak daarbij slim gebruik van je eerdere antwoorden. Gebruik ook de *shortcut formula* voor de variantie (zie pagina 84 van W&S).

■ **Opgave 3.** Maak opgaven 1.4, 2.5, 2.25, en 3.5 uit W&S. De uitwerking van opgave 2.25 vind je in dit werkboek.

■ **Opgave 4.** De volgende vragen gaan over de maten voor ligging en spreiding van een serie waarnemingen.

a) Wanneer gebruiken we het *gemiddelde* als maat om een serie waarnemingen samen te vatten en wanneer kunnen we beter de *mediaan* gebruiken?

b) Wat verstaan we onder de *modus* of de *modale waarde* van een serie waarnemingen?

c) Leg aan de hand van een tekening uit hoe een boxplot een serie waarnemingen kan samenvatten.

d) Stel dat je meetgegevens de dimensie *lengte* hebben, genoteerd als L. Wat is dan de dimensie van (i) het gemiddelde van je meetgegevens, (ii) de standaardafwijking, (iii) de variantie, (iv) de variatiecoëfficiënt?

■ **Opgave 5.** We genereren een aselecte steekproef van vijf sprinkhanen en meten de lengte van iedere sprinkhaan. We vinden: 3,5 inches, 2,4 inches, 3,4 inches, 3,9 inches, en 2,7 inches.

a) Bereken gemiddelde, variantie en standaardafwijking van deze waarden.

b) Hoe veranderen gemiddelde, variantie en standaardafwijking als we van iedere lengte 2 inches aftrekken?

c) Hoe veranderen gemiddelde, variantie en standaardafwijking als we de lengte niet in inches maar in centimeters willen uitdrukken? (1 inch = 2,54 cm).

d) Een stochastische variabele (kansvariabele) Y heeft gemiddelde μ en variantie σ^2. Stel een algemene formule op voor het gemiddelde en de variantie van de getransformeerde variabele $X \equiv a + bY$. (In andere woorden: leg uit wat er in het algemeen gebeurt wanneer je een kansvariabele vermenigvuldigt met b en er een waarde a bij optelt.)

1.2 Week 1, werkcollege B

■ **Opgave 6.** In een bosrijk gebied komen zeven boomsoorten voor. Van ieder soort is het aantal bomen geturfd. De gevonden aantallen zijn samengevat in een frequentietabel (zie Tabel 1.1).

a) Wat is de *populatie* waarover dit onderzoek gaat?

b) Wat is de *variabele* waarnaar wordt gekeken? Van welk type is deze variabele?

c) Geeft Tabel 1.1 relatieve frequenties of de absolute frequenties?

d) Maak een staafdiagram van de *relatieve* frequenties. Denk daarbij na over de meest inzichtelijke volgorde van de staven.

Tabel 1.1: Frequentietabel van waargenomen boomsoorten.

soort	*frequentie*
eik	98
den	85
spar	44
beuk	148
els	24
lariks	19
kastanje	39

■ **Opgave 7.** Maak opgave 2.8 uit W&S.

■ **Opgave 8.** In Tabel 1.2 is voor een zeker gebied de totale hoeveelheid neerslag weergegeven voor de jaren 1950 tot 1999.

a) Wat is hier de variabele? Van welk type is deze variabele?

b) Vat de waarnemingen samen in een frequentietabel. Verdeel hiervoor de waarnemingen over verschillende klassen. Om het aantal klassen te bepalen kun je je laten leiden door Sturges' vuistregel; zie W&S pagina 38 (2^e editie) of pagina 39 (3^e editie).

c) Teken op basis van de frequentietabel een histogram.

Tabel 1.2: Totale neerslag van 1950 tot 1999.

jaar	*regen (mm)*	*jaar*	*regen (mm)*
'67	427	'83	759
'64	540	'71	760
'73	549	'84	764
'55	560	'60	767
'95	563	'74	774
'63	591	'57	780
'99	594	'79	785
'59	618	'96	790
'78	622	'91	795
'88	628	'76	801
'85	639	'80	803
'51	662	'52	808
'72	672	'65	823
'56	683	'89	824
'86	696	'87	827
'61	699	'62	839
'93	707	'94	846
'50	720	'68	859
'77	725	'75	877
'81	727	'66	915
'90	730	'92	932
'69	736	'82	941
'98	740	'54	964
'97	744	'58	991
'70	753	'53	1050

■ **Opgave 9.** Maak opgave 3.9 uit W&S.

■ **Opgave 10.** In een onderzoek is zowel de lengte als het gewicht bepaald van dertien meisjes van twee jaar oud. De gemiddelde lengte is 86,6 cm met een standaarddeviatie van 2,9 cm; het gemiddelde gewicht is 12,6 kg met een standaarddeviatie van 1,4 kg. (Opmerking: De woorden standaardafwijking en standaarddeviatie betekenen hetzelfde.)

a) Bereken de variatiecoëfficiënt voor beide variabelen. Vergelijk beide variatiecoëfficiënten, en interpreteer de resultaten.

b) Op de leeftijd van negen jaar zijn het gewicht en de lengte van dezelfde meisjes opnieuw bepaald. Natuurlijk zijn de meisjes gemiddeld zwaarder en langer geworden. De variatiecoëfficiënten van beide variabelen zijn ook veranderd. Van één van de variabelen is de variatiecoëfficiënt slechts weinig toegenomen; de andere variabele laat een sterk toegenomen variatiecoëfficiënt zien. Welke variatiecoëfficiënt zal volgens jou het meeste toegenomen zijn? Beargumenteer je keuze.

Hint: bedenk hoe genetische en omgevingsfactoren beide variabelen beïnvloeden.

■ **Opgave 11.** In Tabel 1.3 is het geboortegewicht van zes baby's weergegeven. Gebruik de methodes die je geleerd hebt om deze serie getallen te beschrijven.

Tabel 1.3: Geboortegewicht van zes baby's.

baby	*gewicht (g)*
1	3500
2	2900
3	3400
4	1800
5	4200
6	2600

■ **Opgave 12.** Geef de Nederlandse vertaling van de volgende Engelse termen:

estimation • sample • precise • accurate • random sample • categorical • explanatory variable • response variable • frequency distribution • probability distribution • descriptive statistics • outlier • the proportion of a categorical variable • the sample mean • the standard deviation of a sample • the coefficient of variation • the interquartile range.

Reflecteren

{ Onderstaande opgaven zijn bedoeld om je te stimuleren kritisch na te denken over de gepresenteerde leerstof. }

■ **Opgave 13.** We hebben geleerd dat variabelen kunnen worden ingedeeld in verschillende categoriën: categoriale variabelen kunnen nominaal of ordinaal zijn, en numerieke variabelen zijn ofwel discreet ofwel continu.

a) Kun je je variabelen voorstellen waarbij je kunt discussiëren over de vraag of ze numeriek en discreet zijn, of categoriaal en ordinaal?

b) Kun je je variabelen voorstellen waarbij je kunt discussiëren over de vraag of ze discreet of continu zijn?

c) Kun je je variabelen voorstellen waarbij je kunt discussiëren over de vraag of ze nominaal of ordinaal zijn?

■ **Opgave 14.** Tijdens de middelbare school stond op je rapporten waarschijnlijk voor ieder vak het gemiddelde vermeld van alle cijfers die je in de betreffende periode had gehaald. In plaats daarvan zouden scholen ook kunnen kiezen voor de mediaan. Welke voor- en nadelen zou dat hebben? Waar zou jij voor kiezen?

Testen

{ Met behulp van onderstaande opgaven kun je testen of je de stof van dit werkcollege beheerst. Ze zijn bedoeld om je te helpen bij het voorbereiden van het tentamen. Mogelijk kom je er tijdens het werkcollege niet aan toe. }

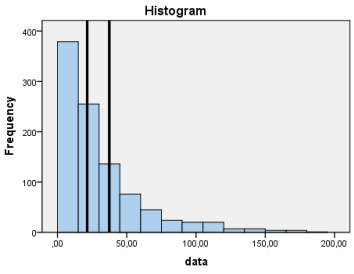
■ **Opgave 15.** Maak deze opgaven uit W&S:

- 2e editie: opgaven 1.7, 1.8, 1.11, 1.14, en 2.22 uit W&S. De uitwerking van opgaven 1.14 en 2.22 staan in dit werkboek.
- 3e editie: opgaven 1.7, 1.8, 1.12, 1.15, en 2.22 uit W&S. De uitwerking van opgaven 1.15 en 2.22 staan in dit werkboek.

■ **Opgave 16.** De twee dikke verticale lijnen in het histogram in Fig. 1.1 geven het gemiddelde en de mediaan aan. Welke uitspraak is waar?

a) De linker lijn toont de mediaan, de rechter lijn het gemiddelde.

b) De rechter lijn toont de mediaan, de linker lijn het gemiddelde.



Figuur 1.1: Histogram.

■ **Opgave 17.** In Tabel 1.3 is van zes baby's het geboortegewicht weergegeven . Wat is de variatiecoëfficiënt van het geboortegewicht?

a) 0,25

b) 0,27

c) 3,70

d) 223,9

■ **Opgave 18.** Door bestraling is de huid van tien patiënten beschadigd. De oppervlakte van de beschadiging is weergegeven in Tabel 1.4. Bereken de meest geschikte locatiemaat (ookwel centrummaat genoemd).

a) de modus: 16 cm^2

b) de mediaan: 18 cm^2

c) de mediaan: 40 cm^2

d) het gemiddelde: 47,3 cm^2

Tabel 1.4: Oppervlakte van beschadigde huid bij tien patiënten.

patiënt	*oppervlakte* (cm^2)
1	42
2	16
3	9
4	10
5	72
6	8
7	16
8	20
9	40
10	240

■ **Opgave 19.** Bij 149 patiënten met een tumor is door bestraling de huid beschadigd. De oppervlakte van de beschadigde huid is bepaald. Van deze patiënten is tevens een tumorclassificatie vastgesteld. Deze classificatie loopt van 1 tot 6 en geeft de aard van de tumor weer. Tabel 1.5 is de frequentietabel van de tumorclassificaties.

Hoe kunnen we de tumorclassificatie en de oppervlakte van de beschadigde huid het beste weergeven?

a) Beide variabelen met een histogram.

b) Beide variabelen met een staafdiagram.

c) De tumorclassificatie met een histogram en de oppervlakte van de beschadigde huid met een staafdiagram.

d) De tumorclassificatie met een staafdiagram en de oppervlakte van de beschadigde huid met een histogram.

Tabel 1.5: Frequentietabel van de classificatie van tumoren in 149 patiënten.

classificatie	*frequentie*
1	22
2	10
3	19
4	47
5	60
6	10

■ **Opgave 20.** Een bioloog doet mee aan de Nationale Tuinvogeltelling en telt hoeveel vogels van elke soort ze in een uur in haar tuin ziet. Welke grafiek zou ze het best kunnen gebruiken om de verdeling van vogelsoorten weer te geven?

a) een histogram

b) een cumulatieve frequentiepolygoon

c) een boxplot

d) een staafdiagram

■ **Opgave 21.** De variabele "percentage bladbeschadiging" is een discrete, numerieke variabele.

a) juist

b) onjuist

Week 2: Schatten

Voorbereiding

Voor aanvang van ieder werkcollege:

- Bestudeer de relevante hoofdstukken uit Whitlock & Schluter (zie de Studiewijzer op Blackboard).
- Bestudeer de dia's van het hoorcollege.
- Hou een lijst bij met vragen over de stof, zodat je die op het werkcollege kunt stellen.

Onderwerpen

Schatten • standaardfout van het gemiddelde • normale verdeling • t-verdeling • betrouwbaarheidsintervallen.

2.1 Week 2, werkcollege A

Verwerken & Oefenen

{ Onderstaande opgaven zijn bedoeld om je te helpen bij het verwerken van de leerstof en het oefenen van vaardigheden. }

■ **Opgave 1.** Maak opgaven 5.10a–e en 5.12 uit W&S.

■ **Opgave 2.** Maak opgaven 10.3 en 10.4 uit W&S.

■ **Opgave 3.** Veronderstel dat de variabele Z standaard-normaal verdeeld is. Bepaal m.b.v. Tabel B in W&S de waarde van Z_0 voor de onderstaande gevallen.

Tip: Maak in alle gevallen een tekening van de situatie!

a) $\Pr(Z > Z_0) = 0{,}05$

b) $\Pr(Z < Z_0) = 0{,}6050$

c) $\Pr(Z < Z_0) = 0{,}05$

d) $\Pr(Z > Z_0) = 0{,}333$

e) $\Pr(Z < -Z_0 \text{ of } Z > Z_0) = 0{,}05$

f) $\Pr(0 < Z < Z_0) = 0{,}45$

■ **Opgave 4.** Veel mensen verwarren de volgende begrippen: (i) de standaardafwijking van de steekproef, (ii) de standaarddeviatie van de steekproef, (iii) de standaardfout van het gemiddelde van de steekproef, (iv) de standaarddeviatie van de steekproefverdeling van het gemiddelde, (v) de variantie van de verdeling van een populatie, (vi) de steekproefvariantie, (vii) de standaarddeviatie van de verdeling van een populatie.

a) Leg voor elk van de bovenstaande termen uit wat ze betekenen.

b) Welk wiskundige symbool hoort bij ieder van de bovenstaande termen? Kies uit: s, s^2 , σ, σ^2, $\mathrm{SE}_{\bar{Y}}$, $\sigma_{\bar{Y}}$.

■ **Opgave 5.** Zijn de volgende uitspraken juist of onjuist?

a) μ is een stochastische variabele (kansvariabele) die van steekproef tot steekproef een andere waarde kan hebben.

b) Bij een aselecte trekking uit een normale verdeling zijn de steekproefmediaan en het steekproefgemiddelde zuivere schatters van μ.

c) Steekproeven worden genomen om informatie te verkrijgen over parameters van de populaties waaruit de steekproeven zijn getrokken.

d) Als we de omvang van een steekproef verdubbelen, halveren we de standaardafwijking van het steekproefgemiddelde.

e) Met de standaardafwijking van een steekproef en de standaardfout van het steekproefgemiddelde wordt precies hetzelfde bedoeld.

f) De verwachte waarde van het steekproefgemiddelde is gelijk aan het populatiegemiddelde.

■ **Opgave 6.** Maak opgave 3.7 uit W&S. Beantwoord daarna de volgende vragen:

a) Bereken een 95%-betrouwbaarheidsinterval voor het gemiddelde verschil in de snelheid voor en na amputatie.

b) Kun je, op basis van het 95%-betrouwbaarheidsinterval dat je zojuist hebt berekend, concluderen dat de gemiddelde snelheden voor en na amputatie significant verschillen? Beargumenteer je antwoord.

■ **Opgave 7.** Maak opgave 4.7 uit het boek van W&S, maar gebruik bij onderdeel e) t-statistiek in plaats van de *approximate method*. Maak hierbij gebruik van onderstaande resultaten, die met R verkregen zijn.

De gegevens zijn eerst in R ingelezen als een data frame met naam `fireflies`. (Als je niet meer zeker weet wat een data frame is, zoek dat dan meteen even op! Je zult die kennis steeds weer nodig hebben.) De structuur van dat data frame is met de functie `str()` opgevraagd:

```
> str(fireflies)
```

```
'data.frame':   35 obs. of  1 variable:
 $ duration: int  79 80 82 83 86 85 86 86 88 87 ...
```

Zorg dat je deze uitvoer helemaal begrijpt!

Met de functie `summary()` kan wat beschrijvende statistiek worden opgevraagd:

```
> summary(fireflies$duration)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  79.00   87.50   95.00   95.94  102.00  119.00
```

Begrijp je wat deze getallen voorstellen?

Met de functie `sd()` is de standaardafwijking berekend:

```
> sd(fireflies$duration)
```

```
[1] 10.9945
```

2.2 Week 2, werkcollege B

■ **Opgave 8.** In een aselecte steekproef van vijf vrouwen is de cholesterolspiegel in het bloed bepaald. Veronderstel dat de cholesterolwaarden normaal verdeeld zijn. De gegevens zijn in R ingevoerd als vector `cholesterol`. (Weet je het verschil nog tussen een vector en een data frame?) Vervolgens zijn deze gegevens geanalyseerd; hieronder volgt zowel de code als de uitvoer:

```
> var(cholesterol)
```

```
[1] 0.425
```

```
> t.test(cholesterol)
```

```

    One Sample t-test

data:  cholesterol
t = 7.5459, df = 4, p-value = 0.001652
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 1.390534 3.009466
sample estimates:
mean of x
      2.2
```

Gebruik deze uitvoer om het gemiddelde van de steekproef, de standaardafwijking van de steekproef, de standaardfout van het gemiddelde, en het 95% betrouwbaarheidsinterval van het gemiddelde te bepalen.

■ **Opgave 9.** Maak opgave 10.13 uit W&S.

■ **Opgave 10.** Wat gebeurt er met een betrouwbaarheidsinterval voor het gemiddelde van een steekproef als je

a) iedere waarneming met 20 eenheden verhoogt?

b) iedere waarneming met 10 vermenigvuldigt?

c) iedere waarneming met 15% verhoogt?

■ **Opgave 11.** Maak opgave 7.4 (2^e editie) of 7.5 (3^e editie) uit W&S.

Reflecteren

$\left\{ \begin{array}{l} \text{Onderstaande opgaven zijn bedoeld om je te stimuleren kritisch} \\ \text{na te denken over de gepresenteerde leerstof.} \end{array} \right\}$

■ **Opgave 12.** Alle standaardmethodes uit de statistiek gaan uit van een aselecte steekproef. Wat denk je — zijn de meeste steekproeven in biologisch onderzoek aselect?

■ **Opgave 13.** Waarom berekenen we meestal een 95%-betrouwbaarheidsinterval, en niet, zeg, een 75%-betrouwbaarheidsinterval?

■ **Opgave 14.** We hebben benadrukt dat een schatting weinig nuttig is als er niet wordt bijverteld hoe *precies* die schatting is. Een betrouwbaarheidsinterval is een goede manier om de precisie aan te geven. De methode die we hebben geleerd om het betrouwbaarheidsinterval voor het gemiddelde te berekenen, vereist echter dat de variabele normaal verdeeld is. Welke opties heb je als je variabele *niet* normaal verdeeld is?

■ **Opgave 15.** Hoe komt het eigenlijk dat veel variabelen, in de biologie en daar buiten, ongeveer normaal verdeeld zijn?

Testen

Met behulp van onderstaande opgaven kun je testen of je de stof van dit werkcollege beheerst. Ze zijn bedoeld om je te helpen bij het voorbereiden van het tentamen. Mogelijk kom je er tijdens het werkcollege niet aan toe.

■ **Opgave 16.** Neem aan dat de kansvariabele Y normaal verdeeld is met $\mu = 10$ en $\sigma^2 = 9$. Wat is $\Pr(8 < Y < 11)$?

a) 0,132

b) 0,378

c) 0,471

d) 0,622

■ **Opgave 17.** De standaardfout van het gemiddelde kan groter zijn dan de standaardafwijking van de steekproef.

a) Juist

b) Onjuist

■ **Opgave 18.** Een 70% betrouwbaarheidsinterval van het gemiddelde bevat in 70% van de gevallen het ware populatiegemiddelde.

a) Juist

b) Onjuist

■ **Opgave 19.** Als de verdeling van een variabele scheef is, en de steekproef is klein, dan mag je ervan uitgaan dat het steekproefgemiddelde normaal verdeeld is.

a) Juist

b) Onjuist

■ **Opgave 20.** Neem aan dat in een populatie van vrouwen de hartfrequentie normaal verdeeld is met een gemiddelde $\mu = 75$ /min en een standaardafwijking $\sigma = 11$ /min. Binnen welke grenzen zal 95% van de hartslagen van alle vrouwen liggen?

a) tussen 72,8 en 77,2 /min

b) tussen 64,0 en 86,0 /min

c) tussen 56,9 en 93,1 /min

d) tussen 53,4 en 96,6 /min

■ **Opgave 21.** Een aselecte steekproef van negen tomaten wordt gewogen; de resultaten staan in Tabel 2.6. Wat is voor deze steekproef de standaardfout van het gemiddelde gewicht?

a) 4,240 g

b) 1,997 g

c) 1,413 g

d) 1,332 g

Tabel 2.6: Gewichten van negen tomaten.

tomaat	*gewicht* (g)
1	16,2
2	24,1
3	22,7
4	16,1
5	21,9
6	23,3
7	14,6
8	21,2
9	12,9

■ **Opgave 22.** Deze opgave gaat wederom over de gegevens uit Tabel 2.6. Welke kritieke tabelwaarde moet worden gebruikt bij het berekenen van een 95%-betrouwbaarheidsinterval voor het populatiegemiddelde van de gewichten?

a) 2,31

b) 2,26

c) 1,96

d) 1,83

■ **Opgave 23.** Van zestien aselect gekozen tomaten uit een kas is het gewicht bepaald. Het gemiddelde gewicht is gelijk aan 44,1 g; de standaardafwijking van de gewichten is gelijk aan 8,6 g. Bepaal het 95%-betrouwbaarheidsinterval voor het gemiddelde gewicht μ van dergelijke tomaten. (Neem aan dat de gewichten normaal verdeeld zijn.)

a) [25,8 g; 62,4 g]

b) [27,2 g; 61,0 g]

c) [39,5 g; 48,7 g]

d) [39,9 g; 48,3 g]

De notatie van intervallen is in het Nederlands wat verwarrend. Omdat het Nederlands een komma gebruikt als scheidingsteken voor de decimalen (zoals in het getal 1,4), is het onhandig om bij het noteren van een interval ook een komma te gebruiken om de twee getallen te scheiden. Daarom gebruiken we, als er anders verwarring ontstaat, een puntkomma.

■ **Opgave 24.** Maak opgave 7.7 (2e editie) of 7.8 (3e editie) uit W&S.

Week 3: Toetsen

Voorbereiding

Voor aanvang van ieder werkcollege:

- Bestudeer de relevante hoofdstukken uit Whitlock & Schluter (zie de Studiewijzer op Blackboard).
- Bestudeer de dia's van het hoorcollege.
- Hou een lijst bij met vragen over de stof, zodat je die op het werkcollege kunt stellen.

Onderwerpen

Algemene toetsingstheorie • t-toetsen • 1-weg ANOVA • post-hoc toetsen

3.1 Week 3, werkcollege A

Verwerken & Oefenen

{ Onderstaande opgaven zijn bedoeld om je te helpen bij het verwerken van de leerstof en het oefenen van vaardigheden. }

■ **Opgave 1.** Maak uit W&S de volgende opgaven:

2e editie 6.7 en 6.8.

3e editie 6.6 en 6.7.

■ **Opgave 2.** We veronderstellen dat het gewicht van kippeneieren normaal verdeeld is. Een poelier beweert dat zijn eieren gemiddeld 52 g wegen. Wij geloven dat niet zomaar.

a) We wegen daarom aselect één van zijn eieren; het weegt 51,7 g. Bereken het gemiddelde en de variantie van deze kleine steekproef.

b) We wegen nog drie eieren, met de volgende gewichten: 50,3 g; 48,4 g; en 51,9 g. (Je hebt nu dus vier metingen.) Formuleer een nulhypothese en een alternatieve hypothese. Welke statistische toets zou je willen uitvoeren? Wat is de toetsingsgrootheid en wat is zijn verdeling onder de nulhypothese? Wat is de kritieke waarde van de toetsingsgrootheid? Teken het verwerpingsgebied.

Let op: Tenzij anders is aangegeven, kun je in alle opgaven uit gaan van een significantieniveau van $\alpha = 0{,}05$.

c) Voer de toets uit. Zou je H_0 op grond van deze waarnemingen verwerpen?

d) Gebruik Tabel C uit W&S om de overschrijdingskans te schatten.

Overschrijdingskans is een net woord voor P-waarde.

■ **Opgave 3.** De volgende vragen gaan over de verschillende t-toetsen die we hebben behandeld.

a) Wat zijn de aannames die horen bij een t-toets voor gepaarde waarnemingen? Hoe kun je die aannames controleren?

b) Aan welke aannames moet worden voldaan om een t-toets voor twee steekproeven uit te mogen voeren? Hoe kun je die aannames controleren?

c) Wat is het verschil tussen een t-toets voor twee steekproeven en een t-toets voor gepaarde waarnemingen?

d) Wat is het verschil tussen een t-toets voor één steekproef en een t-toets voor gepaarde waarnemingen? Zijn er ook overeenkomsten?

■ **Opgave 4.** Maak opgave 11.10 uit W&S. Let op: W&S doen hier een éénzijdige toets. Omdat eenzijdig toetsen omstreden is, is het ook prima als je een tweezijdige toets uitvoert. In dit geval verandert dat ook de conclusie niet.

■ **Opgave 5.** In Tabel 3.7 staan diastolische bloeddrukwaarden die gemeten zijn bij een steekproef van 50 mannen. De gegevens zijn in R ingevoerd als vector `bloeddruk` en daarna als volgt geanalyseerd:

Tabel 3.7: Diastolische bloeddruk van 50 mannen (in mm Hg).

94	94	82	100	112
110	84	78	92	112
94	92	86	84	90
72	88	92	88	84
98	98	84	90	90
70	80	90	80	106
74	95	100	94	84
70	102	92	84	80
84	86	98	82	80
88	80	84	100	86

```
> t.test(bloeddruk, mu = 90)
```

```
    One Sample t-test

data:  bloeddruk
t = -0.61263, df = 49, p-value = 0.543
alternative hypothesis: true mean is not equal to 90
95 percent confidence interval:
 86.31898 91.96102
sample estimates:
mean of x
    89.14
```

a) Bestudeer de uitvoer; zorg dat je de structuur en inhoud ervan begrijpt.

b) Welke toets wordt precies uitgevoerd? Stel de nulhypothese en de alternatieve hypothese op. Welke aannames moet men maken om deze toets uit te voeren?

c) Lees de toetsingsgrootheid en bijbehorende overschrijdingskans af. Wat is je conclusie ten aanzien van de gestelde hypotheses, aangenomen dat aan de voorwaarden is voldaan?

d) Lees het 95%-betrouwbaarheidsinterval voor het populatiegemiddelde af uit de uitvoer.

e) Wat is het verband tussen de antwoorden op onderdelen c) en d)?

■ **Opgave 6.** Maak de volgende opgaven uit W&S:

2e editie van opgave 12.14 onderdelen (a), (b), (d), en daarna opgave 12.5.

3e editie van opgave 12.13 onderdelen (a), (b), (d), en daarna opgave 12.5.

De antwoorden staan achterin W&S. Maar let op: er staat afhankelijk van de druk van je boek mogelijk een foutje in de uitwerkingen. In de uitwerking bij (b) wordt in dat geval gesproken over “weight” terwijl het over “length” zou moeten gaan.

■ **Opgave 7.** Onderzoekers zijn geïnteresseerd in het effect van levertraan op de groei van kuikens. Daarom werden tien jonge kuikens gevoed met een mengvoer waaraan 1% levertraan was toegevoegd. Als controlegroep werden 20 soortgelijke kuikens gevoed met hetzelfde mengvoer waaraan 1% van een andere olie was toegevoegd. Na acht dagen werd van ieder kuiken het gewicht gemeten (in gram).

De gegevens zijn in R geanalyseerd. Daartoe is eerst een data frame gemaakt, genaamd `kuikens`, met de volgende structuur:

```
> str(kuikens)
```

```
'data.frame':   30 obs. of  2 variables:
 $ gewicht: num  65.3 67.5 64.7 71.3 67.9 ...
 $ olie   : Factor w/ 2 levels "controle","levertraan": 1 1 1 1 1 1 1 1 1 ...
```

Zoals je ziet, heeft dit data frame twee kolommen. De eerste bevat de gemeten gewichten; het is een numerieke variabele met naam `gewicht`. De tweede specificeert voor ieder regel van de data frame tot welke groep het behoort; het is een categoriale variabele ("factor") met twee niveaus (`controle` en `levertraan`) en heeft de naam `olie`.

Daarna is het volgende commando uitgevoerd:

```
> t.test(gewicht ~ olie, data = kuikens, var.equal = TRUE)
```

```
    Two Sample t-test

data:  gewicht by olie
t = -2.34, df = 28, p-value = 0.02664
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -4.0723829 -0.2705578
sample estimates:
  mean in group controle mean in group levertraan
                67.51346                 69.68493
```

a) Welke toets wordt uitgevoerd? Bestudeer de invoer en de uitvoer; zorg dat je de structuur en inhoud ervan begrijpt.

b) Geef aan welke hypothese hier wordt getoetst en formuleer ook de alternatieve hypothese.

c) Geef een puntschatting voor het verschil in het gemiddelde gewicht van beide populaties.

d) In de functie `t.test()` hierboven wordt de optie `var.equal = TRUE` gebruikt. Wat is de consequentie daarvan?

e) Bepaal het 95%-betrouwbaarheidsinterval voor het verschil in gemiddelden tussen beide populaties, aannemend dat de beide populatievarianties gelijk zijn en de gewichten in beide populaties normaal verdeeld zijn.

f) Er wordt nog een analyse uitgevoerd:

```
> by(kuikens$gewicht, kuikens$olie, sd)
```

```
kuikens$olie: controle
[1] 2.461219
------------------------------------------------------------------------------
```

```
kuikens$olie: levertraan
[1] 2.252367
```

Zorg dat je begrijpt wat de functie `by()` doet.

```
> library("car")
> leveneTest(gewicht ~ olie, data = kuikens)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  1  0.1192 0.7325
      28
```

Vind je het op basis van de uitvoer verantwoord om te veronderstellen dat de varianties van beide behandelgroepen gelijk zijn? Beargumenteer je antwoord.

g) Trek je conclusie over de nulhypothese dat er geen verschil is tussen de beide populatiegemiddelden. Doe dit op drie manieren: (i) Op basis van de overschrijdingskans, (ii) op basis van de toetsingsgrootheid en de bijbehorende kritieke waarde, en (iii) op basis van het betrouwbaarheidsinterval uit onderdeel e).

■ **Opgave 8.** Een onderzoeker vermoedt dat onder invloed van zonlicht de zuurgraad van vijvers kan veranderen. Om dit vermoeden te toetsen meet hij in negen vijvers zowel 's ochtends als 's avonds de pH. De verkregen gegevens zijn geanalyseerd met R:

```
> zuurgraadOchtend <- c(4.89, 5.28, 5.24, 5.27, 4.92, 5.35, 4.76, 5.72, 4.62)
> zuurgraadAvond <- c(5.29, 5.51, 5.75, 5.62, 5.42, 6.09, 4.92, 6.01, 5.34)
> t.test(zuurgraadOchtend, zuurgraadAvond, paired = TRUE)
```

```
    Paired t-test

data:  zuurgraadOchtend and zuurgraadAvond
t = -6.3892, df = 8, p-value = 0.0002116
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.5897341 -0.2769325
sample estimates:
mean of the differences
             -0.4333333
```

a) Geef een schatting van de effectgrootte. Geef er ook een 95% betrouwbaarheidsinterval bij, aannemend dat aan de aannames is voldaan.

b) Formuleer de hypotheses die de onderzoeker wil toetsen. Welke toets hoort hierbij? Wat is op grond van de uitvoer je conclusie ten aanzien van deze hypotheses? Geef hierbij ook de overschrijdingskans.

De *effectgrootte* is de grootte van het effect dat je met de toets wilt aantonen – in dit geval dus de grootte van de gemiddelde toename van de pH. De vraag *of* er een effect is, is vaak veel minder relevant dan de vraag *hoe groot* het effect is!

■ **Opgave 9.** Maak uit W&S opgave 12.13 (2^e editie) of 12.12 (3^e editie).

3.2 Week 3, werkcollege B

■ **Opgave 10.** In een onderzoek heeft men gekeken naar de hoeveelheid voedsel die per dag door een volwassen hert wordt geconsumeerd.

Tabel 3.8: Consumptie van voedsel door volwassen herten tijdens verschillende jaargetijden.

	consumptie (kg/dag)				
	feb.	*mei*	*aug.*	*nov.*	*totaal*
	4,7	4,6	4,8	4,9	
	4,9	4,4	4,7	5.2	
	5,0	4,3	4,6	5,4	
	4,8	4,4	4,4	5,1	
	4,7	4,1	4,7	5,6	
		4,2	4,8		
gemiddelde	4,820	4,333	4,667	5,240	4,741
s	0,1304	0,1751	0,1506	0,2702	

Men wil met name weten of de gemiddelde dagconsumptie afhangt van het jaargetijde. Hiertoe is in de maanden februari, mei, augustus en november steeds van vijf of zes herten de consumptie bijgehouden; zie Tabel 3.8.

a) Hoe zou je een dergelijk onderzoek opzetten?

b) Formuleer de nulhypothese en de alternatieve hypothese.

c) Toets de in onderdeel b) gestelde hypotheses. (Maak daarbij handig gebruik van de gegevens in de tabel!)

d) Welke aannames moet je maken om de toets in onderdeel c) te mogen uitvoeren?

e) Zou het het in dit geval zinvol zijn om post-hoc-toetsen uit te voeren? Leg uit.

■ **Opgave 11.** Maak uit W&S opgave 15.5 (2^e editie) of 15.4 (3^e editie).

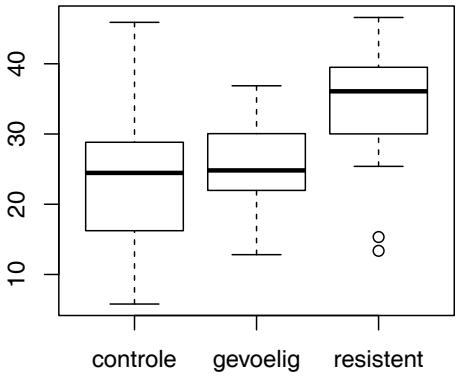
■ **Opgave 12.** In een onderzoek vergelijkt men de vruchtbaarheid van drie lijnen van *Drosophila melanogaster*, te weten een lijn die resistent is voor DDT, een lijn die gevoelig is voor DDT en een controlelijn. Voor elke lijn selecteert men evenveel vrouwtjes. De vruchtbaarheid wordt per vrouwtje uitgedrukt als het aantal gelegde eitjes per dag (bepaald gedurende de eerste 14 levensdagen).

De gegevens zijn in R ingelezen als een dataframe met de naam `drosophila`. De volgende analyse is uitgevoerd:

```
> str(drosophila)
```

```
'data.frame':   75 obs. of  2 variables:
 $ eitjes: num  24.3 30.1 34.9 22.6 34.4 ...
 $ groep : Factor w/ 3 levels "controle","gevoelig",..: 3 3 3 3 3 3 3 3 3 3 ...
```

```
> boxplot(eitjes ~ groep, data = drosophila)
```



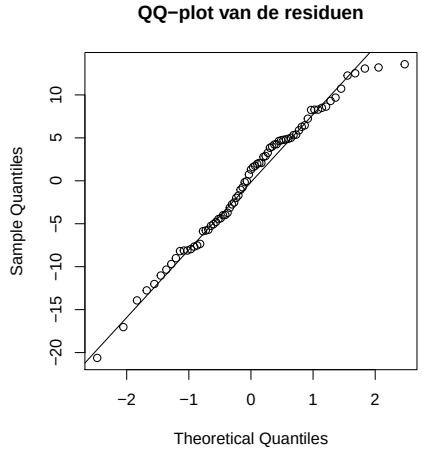

```
> by(drosophila$eitjes, drosophila$groep, summary)
```

```
drosophila$groep: controle
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  6.435  18.415  25.444  23.468  29.930  35.988
------------------------------------------------------------------------
drosophila$groep: gevoelig
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  6.064  21.448  28.282  26.688  32.560  39.761
------------------------------------------------------------------------
drosophila$groep: resistent
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  18.15   24.46   30.00   30.16   34.39   43.73
```

```
> library("car")
> leveneTest(eitjes ~ groep, data = drosophila)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  2  0.6208 0.5404
      72
```

```
> resultaat <- lm(eitjes ~ groep, data = drosophila)
> qqnorm(resultaat$residuals, main = "QQ-plot van de residuen");
  qqline(resultaat$residuals)
```




```
> anova(resultaat)
```

```
Analysis of Variance Table

Response: eitjes
          Df Sum Sq Mean Sq F value  Pr(>F)
```

```
groep       2  560.3 280.151  4.6836 0.01224 *
Residuals 72 4306.7  59.815
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> summary(resultaat)

Call:
lm(formula = eitjes ~ groep, data = drosophila)

Residuals:
    Min      1Q  Median      3Q     Max
-20.624  -5.470   1.307   5.159  13.572

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)      23.468      1.547  15.172  < 2e-16 ***
groepgevoelig     3.220      2.188   1.472  0.14541
groepresistent    6.693      2.188   3.060  0.00311 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.734 on 72 degrees of freedom
Multiple R-squared:  0.1151,    Adjusted R-squared:  0.09054
F-statistic: 4.684 on 2 and 72 DF,  p-value: 0.01224
```

a) Hoeveel vrouwtjes zijn er per groep in dit onderzoek gebruikt?

b) De onderzoekers hebben een ANOVA uitgevoerd. Welk aannames moeten de onderzoekers daartoe maken? Voldoen de gegevens aan deze aannames? (Leg altijd precies uit op welke uitvoer je je antwoord baseert!)

c) Welke hypothese hebben de onderzoekers met behulp van de ANOVA getoetst? Formuleer je conclusies ten aanzien van deze hypotheses met behulp van de uitvoer.

d) De onderzoekers besluiten post-hoc-toetsen uit te voeren. (Zie de uitvoer van de functie `summary()`.) Hierbij willen ze gebruik maken van een Bonferroni-correctie. Gegeven dat een Bonferroni-correctie wordt uitgevoerd, wat is dan jouw conclusie over het verschil in vruchtbaarheid tussen de resistente lijn en de controle-lijn?

Reflecteren

{ Onderstaande opgaven zijn bedoeld om je te stimuleren kritisch na te denken over de gepresenteerde leerstof. }

■ **Opgave 13.** Maak uit W&S de volgende opgaven:

2e editie 6.9 en 6.10.

3e editie 6.8 en 6.9.

■ **Opgave 14.** Stel, 20 onderzoeksgroepen verspreid over de gehele wereld onderzoeken ieder één hypothese. Alle alternatieve hypotheses lijken bij voorbaat zeer onwaarschijnlijk. Alle groepen gebruiken $\alpha = 0{,}05$. Hoeveel onderzoeken zullen naar verwachting de nulhypothese

verwerpen? Hoeveel onderzoeken zul je naar verwachting teruglezen in een wetenschappelijk tijdschrift? Als je in een tijdschrift leest dat er een significant verschil is tussen twee groepen, met $P = 0{,}03$ – is dat dan zwaarwegend bewijs?

■ **Opgave 15.** Een onderzoeksgroep onderzoekt of een cosmetisch product kankerverwekkend is door één groep muizen langdurig, en één groep muizen helemaal niet aan het product bloot te stellen. De conclusie is: er is geen verschil is tussen de groepen ($P = 0{,}18$), dus het product is veilig. Wat denk jij?

Testen

Met behulp van onderstaande opgaven kun je testen of je de stof van dit werkcollege beheerst. Ze zijn bedoeld om je te helpen bij het voorbereiden van het tentamen. Waarschijnlijk kom je er tijdens het werkcollege niet aan toe.

■ **Opgave 16.** Een bioloog doet de volgende uitspraak: "Het verschil tussen de steekproefgemiddelden van groep A en groep B is niet statistisch significant met $\alpha = 0{,}05$." Welke uitspraak is waar:

a) De test toont aan dat H_A op basis van deze steekproef moet worden verworpen.

b) De steekproefgemiddelden van A en B verschillen niet van elkaar.

c) De steekproefgemiddelden van A en B verschillen minder dan 5% van elkaar.

d) De overschrijdingskans P onder aanname van H_0 is groter dan 5%.

■ **Opgave 17.** Stel: je voert een toets uit met $\alpha = 0{,}05$. Je vindt dat $P = 0{,}08$; daarom verwerp je H_0 niet. Wat is de kans dat je een fout maakt van type I?

a) 0

b) 0,05

c) 0,08

d) 0,95

■ **Opgave 18.** Als de P-waarde bij de Levene's toets groter is dan 0,05 dan zijn de varianties verschillend.

a) juist

b) onjuist

■ **Opgave 19.** Anna en Suzanne doen onafhankelijk precies hetzelfde onderzoek, maar met verschillende steekproefgrootte: Anna onderzoekt 20 proefpersonen, Suzanne onderzoekt er 100. Veronderstel dat de nulhypothese waar is. Dan heeft Anna een grotere kans om $P < 0{,}01$ te vinden dan Suzanne.

a) Juist

b) Onjuist

■ **Opgave 20.** Anna en Suzanne doen onafhankelijk precies hetzelfde onderzoek, maar met verschillende steekproefgrootte: Anna onderzoekt 20 proefpersonen, Suzanne onderzoekt er 100. Allebei gebruiken ze een t-test om de hypothese te testen dat het populatiegemiddelde 5 is. Dan is de kritieke waarde behorende bij Anna's toets groter dan die van Suzannes toets.

a) Juist

b) Onjuist

■ **Opgave 21.** Een studie bekijkt hoe de lichaamstemperatuur van muizen verandert als gevolg van een virusinfectie. Van 25 gezonde muizen is de temperatuur gemeten in graden Celcius (temperatuur "voor"). Vervolgens zijn de muizen geïnfecteerd met een virus; een dag daarna is de lichaamstemperatuur weer gemeten (temperatuur "na"). In R zijn twee verschillende analyses uitgevoerd. Alle in- en uitvoer is hieronder weergegeven, maar let op: in de uitvoer is een aantal getallen gemaskeerd (vervangen door xxxxxxxx).

```
> str(muizen)
```

```
'data.frame':   50 obs. of  2 variables:
 $ temperatuur: num  36.4 37.2 36.2 38.6 37.3 ...
 $ moment     : Factor w/ 2 levels "voor","na": 1 1 1 1 1 1 1 1 1 1 ...
```

```
> by(muizen$temperatuur, muizen$moment, summary)
```

```
muizen$moment: voor
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  34.79   36.69   37.39   37.17   37.78   38.60
------------------------------------------------
muizen$moment: na
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  34.99   37.03   37.68   37.50   38.42   39.19
```

```
> by(muizen$temperatuur, muizen$moment, sd)
```

```
muizen$moment: voor
[1] 0.950108
------------------------------------------------
muizen$moment: na
[1] 1.142414
```

```
> t.test(temperatuur ~ moment, data = muizen, var.equal = TRUE)
```

```
    Two Sample t-test

data:  temperatuur by moment
t = -1.118, df = xxxxxxxx, p-value = xxxxxxxx
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.9297406  0.2652779
sample estimates:
mean in group voor   mean in group na
          37.16867           37.50090
```

```
> t.test(temperatuur ~ moment, data = muizen, paired = TRUE)
```

```
    Paired t-test

data:  temperatuur by moment
t = -2.352, df = xxxxxxxx, p-value = xxxxxxxx
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.62376967 -0.04069303
sample estimates:
mean of the differences
```

a) Bereken het 95%-betrouwbaarheidsinterval van de gemiddelde temperatuur van *gezonde* muizen.

b) Schat m.b.v. de uitvoer en Tabel C in W&S de overschrijdingskans van de correcte toets.

c) Welke aannames moet je maken om de toets uit onderdeel b) te mogen toepassen?

■ **Opgave 22.** Milieubiologen willen weten of bij de teelt van suikermaïs schadelijke insecten bestreden kunnen worden met behulp van biologische bestrijding. In een experiment maakte men vijf groepen van twaalf zaailingen: een controlegroep (groep 1), en vier groepen waarin organismen werden ingezet om schadelijke insecten te bestrijden (groep 2: nematoden; groep 3: parasitaire wespen; groep 4: nematoden en parasitaire wespen; groep 5: bacteriën). Na 3 maanden bepaalde men de opbrengst door van elke plant random een maïskolf te selecteren en deze te wegen. De gegevens zijn ingeladen in R als dataframe `mais` en vervolgens geanalyseerd. De volledige analyse volgt hieronder; daaronder beginnen de vragen.

```
> str(mais)
```

```
'data.frame':   60 obs. of  2 variables:
 $ opbrengst  : num  9.41 12.22 8.68 17.12 12.73 ...
 $ behandeling: Factor w/ 5 levels "controle","nem",..: 2 2 2 2 2 2 2 2 2 2 ...
```

```
> by(mais$opbrengst, mais$behandeling, mean)
```

```
mais$behandeling: controle
[1] 12.81933
------------------------------------------------------------------------------
mais$behandeling: nem
[1] 12.51507
------------------------------------------------------------------------------
mais$behandeling: wesp
[1] 9.700336
------------------------------------------------------------------------------
mais$behandeling: nem en wesp
[1] 10.11676
------------------------------------------------------------------------------
mais$behandeling: bacterien
[1] 11.64034
```

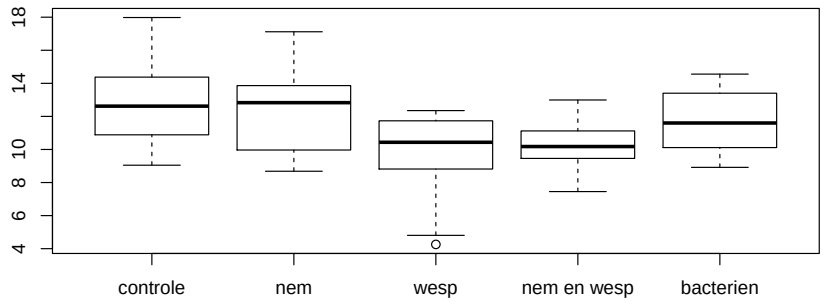
```
> by(mais$opbrengst, mais$behandeling, sd)
```

```
mais$behandeling: controle
[1] 2.718107
------------------------------------------------------------------------------
```

```
mais$behandeling: nem
[1] 2.8129
------------------------------------------------------------------------------------
mais$behandeling: wesp
[1] 2.721854
------------------------------------------------------------------------------------
mais$behandeling: nem en wesp
[1] 1.551781
------------------------------------------------------------------------------------

mais$behandeling: bacterien
[1] 1.929934
```

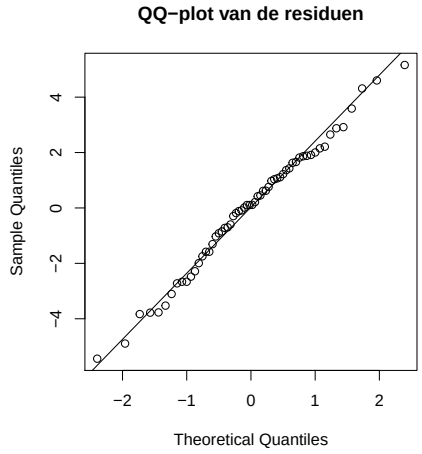
```
> boxplot(opbrengst ~ behandeling, data = mais)
```




```
> library("car")
> leveneTest(opbrengst ~ behandeling, data = mais)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  4  1.1206 0.3562
      55
```

```
> resultaat <- lm(opbrengst ~ behandeling, data = mais)
> qqnorm(resultaat$residuals, main = "Normal QQ Plot of residuals"); qqline(
    resultaat$residuals)
```




```
> anova(resultaat)
```

```
Analysis of Variance Table

Response: opbrengst
            Df Sum Sq Mean Sq F value   Pr(>F)
behandeling  4  94.11 23.5276  4.0788 0.005758 **
Residuals   55 317.26  5.7683
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> summary(resultaat)
```

```

Call:
lm(formula = opbrengst ~ behandeling, data = mais)

Residuals:
    Min      1Q  Median      3Q     Max
-5.4409 -1.5808  0.1086  1.6370  5.1604

Coefficients:
                       Estimate Std. Error t value Pr(>|t|)
(Intercept)             12.8193     0.6933  18.490  < 2e-16 ***
behandelingnem          -0.3043     0.9805  -0.310  0.75749
behandelingwesp         -3.1190     0.9805  -3.181  0.00241 **
behandelingnem en wesp  -2.7026     0.9805  -2.756  0.00791 **
behandelingbacterien    -1.1790     0.9805  -1.202  0.23435
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.402 on 55 degrees of freedom
Multiple R-squared:  0.2288,    Adjusted R-squared:  0.1727
F-statistic: 4.079 on 4 and 55 DF,  p-value: 0.005758
```

a) Hoe zou jij een dergelijk onderzoek opzetten?

b) Welke informatie uit bovenstaande analyse kun je gebruiken om te bekijken of de gegevens voldoen aan de aannames van ANOVA? Vind je het, op basis van deze informatie, verantwoord een ANOVA te gebruiken?

c) Welke hypotheses hebben de onderzoekers door middel van de ANOVA getoetst? Formuleer je conclusies ten aanzien van deze hypotheses op basis van de uitvoer van R.

d) De onderzoekers hebben post-hoc-vergelijkingen uitgevoerd en concluderen dat er een verschil in opbrengst is tussen behandelingsgroepen 1 (controle) en 4 (nematode en parasitaire wespen). Ben jij het eens met hun conclusie?

Week 4: Relaties

Voorbereiding

Voor aanvang van ieder werkcollege:

- Bestudeer de relevante hoofdstukken uit Whitlock & Schluter (zie de Studiewijzer op Blackboard).
- Bestudeer de dia's van het hoorcollege.
- Hou een lijst bij met vragen over de stof, zodat je die op het werkcollege kunt stellen.

Onderwerpen

Correlatie • correlatiecoëfficiënt • lineaire regressie • regressiecoëfficiënt • voorspellingsinterval

4.1 Week 4

Verwerken & Oefenen

{ Onderstaande opgaven zijn bedoeld om je te helpen bij het verwerken van de leerstof en het oefenen van vaardigheden. }

■ **Opgave 1.** Een onderzoeker leest in de literatuur dat er bij mensen slechts een kleine correlatie is tussen het hemoglobinegehalte en het lichaamsgewicht. De onderzoeker wil dit met een klein onderzoek controleren. Hij test twee mensen en vindt tot zijn verbazing dat de correlatiecoëfficiënt $r = 1{,}000$. Hij concludeert dat de auteurs van het artikel het helemaal bij het verkeerde eind hebben: de correlatie is juist erg groot! Ben je het eens met deze redenering?

■ **Opgave 2.** Hieronder volgen een paar vragen over correlatie en regressie.

a) Welke dimensie heeft de correlatiecoëfficiënt? En welke de covariantie?

b) Bespreek het verschil tussen de Pearson en Spearman correlatiecoëfficiënt.

c) Beschrijf aan de hand van een tekening het intercept en de richtingscoëfficiënt van de regressielijn.

d) Bespreek de *betekenis* van de richtingscoëfficiënt van een regressielijn.

e) Beschrijf het verschil tussen de correlatie tussen Y en X en de regressie van Y op X.

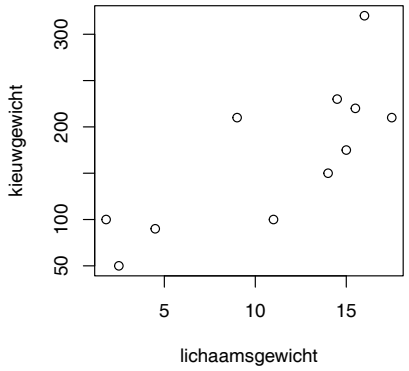
f) Is de correlatiecoëfficiënt gerelateerd aan de richtingscoëfficiënt van de regressielijn?

■ **Opgave 3.** Maak opgaven 16.5, maar je hoeft geen standaardfout en betrouwbaarheidsinterval uit te rekenen; maak daarna opgaven 16.6, 16.8 en 16.9 uit W&S.

■ **Opgave 4.** Maak opgaven 17.8, 17.13, 17.14 en 17.16 uit W&S.

■ **Opgave 5.** In een studie wil men weten of er een correlatie bestaat tussen het kieuwgewicht en het lichaamsgewicht van een krab. Hiertoe werden van 11 krabben beide gewichten bepaald. Het kieuwgewicht is in R ingevoerd (in mg) als vector `kieuwgewicht`, en het lichtaamsgewicht (in g) is in R ingevoerd als vector `lichaamsgewicht`. De volgende code werd uitgevoerd:

```
plot(lichaamsgewicht, kieuwgewicht)
```




```
cor.test(lichaamsgewicht, kieuwgewicht)
```

```
    Pearson's product-moment correlation

data:  lichaamsgewicht and kieuwgewicht
t = 3.6596, df = 9, p-value = 0.005239
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3236097 0.9380527
sample estimates:
      cor
0.7733566
```

a) Wat is vanuit biologisch oogpunt je verwachting omtrent het verband tussen het kieuw- en lichaamsgewicht?

b) Interpreteer het spreidingsdiagram. Lijkt je verwachting uit onderdeel a) te worden bevestigd?

c) Lees de correlatiecoëfficiënt r af uit de uitvoer.

d) Stel de nulhypothese op die je zou willen toetsen; schrijf ook de alternatieve hypothese op.

e) Wat is de overschrijdingskans van de toets die bij de nul-hypothese uit onderdeel d) hoort?

f) Welke aannames moet je maken om deze toets te mogen gebruiken? Is aan die aannames voldaan?

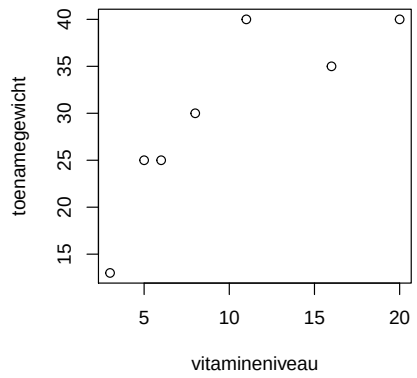
g) Wat zijn je conclusies?

■ **Opgave 6.** Bij het bestuderen van de invloed van een vitamine op het lichaamsgewicht is bij zeven dieren het vitamineniveau en de toename in lichaamsgewicht in een bepaalde periode gemeten. De gegevens zijn in R geanalyseerd:

```
> str(vitamines)
```

```
'data.frame':   7 obs. of  2 variables:
 $ vitamineniveau: num  3 5 6 8 11 16 20
 $ toenamegewicht: num  13 25 25 30 40 35 40
```

```
> plot(vitamines)
```




```
> resultaat <- lm(toenamegewicht ~ vitamineniveau, data = vitamines)
> anova(resultaat)
```

```
Analysis of Variance Table

Response: toenamegewicht
               Df Sum Sq Mean Sq F value  Pr(>F)
vitamineniveau  1 399.56  399.56  12.192 0.01744 *
Residuals       5 163.86   32.77
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> summary(resultaat)
```

```
Call:
lm(formula = toenamegewicht ~ vitamineniveau, data = vitamines)

Residuals:
      1       2       3       4       5       6       7
-7.6931  1.6757  0.3601  2.7290  8.7822 -2.7958 -3.0582

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)     16.7463     4.2983   3.896   0.0115 *
vitamineniveau   1.3156     0.3768   3.492   0.0174 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
Residual standard error: 5.725 on 5 degrees of freedom
Multiple R-squared:  0.7092,    Adjusted R-squared:  0.651
F-statistic: 12.19 on 1 and 5 DF,  p-value: 0.01744
```

a) Geef de vergelijking van de regressielijn.

b) Gebruik de uitvoer om te toetsen of de regressiecoëfficiënt (de helling van de regressielijn) gelijk is aan nul, ervan uitgaand dat aan de aannames van regressieanalyse is voldaan.

c) Geef een voorspelling voor de gemiddelde toename in lichaamsgewicht bij een vitamineniveau van 25.

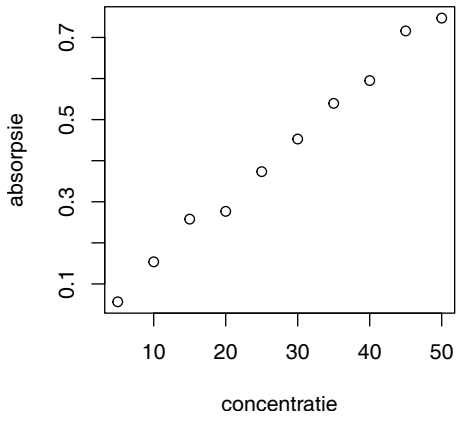
d) Men kan op de voorspellingen die je in onderdeel c) gegeven hebt gegronde kritiek leveren. Hoe luidt deze?

■ **Opgave 7.** In een experiment heeft men de UV-absorptie van een eiwit bepaald bij een golflengte van 280 nm bij verschillende concentraties van het eiwit. De gegevens zijn in R geanalyseerd:

```
> str(UV)
```

```
'data.frame':   10 obs. of  2 variables:
 $ concentratie: num  5 10 15 20 25 30 35 40 45 50
 $ absorpsie   : num  0.0621 0.1538 0.2078 0.3329 0.3818 ...
```

```
> plot(UV)
```




```
> resultaat <- lm(absorpsie ~ concentratie, data = UV)
> anova(resultaat)
```

```
Analysis of Variance Table

Response: absorpsie
            Df  Sum Sq Mean Sq F value    Pr(>F)
concentratie  1 0.48915 0.48915  1157.4 6.088e-10 ***
Residuals     8 0.00338 0.00042
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> summary(resultaat)
```

```
Call:
lm(formula = absorpsie ~ concentratie, data = UV)

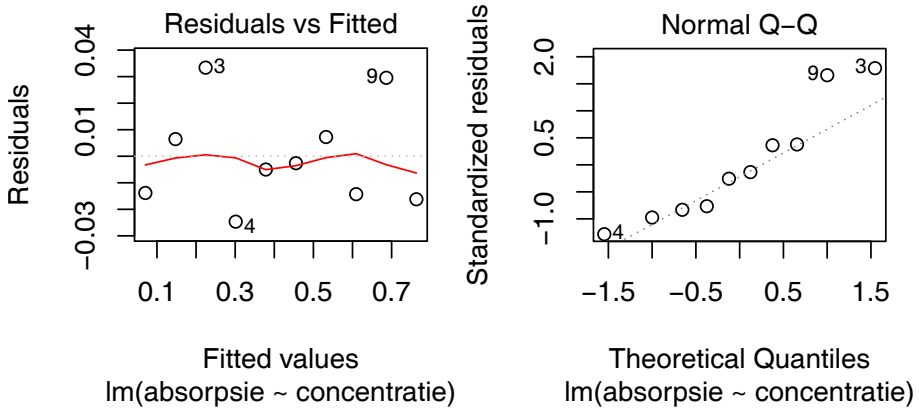
Residuals:
      Min        1Q    Median        3Q       Max
```

```
-0.024656 -0.014182 -0.003815  0.007046  0.033382

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.0066491  0.0140435  -0.473    0.649
concentratie  0.0154001  0.0004527  34.021 6.09e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.02056 on 8 degrees of freedom
Multiple R-squared:  0.9931,    Adjusted R-squared:  0.9923
F-statistic:  1157 on 1 and 8 DF,  p-value: 6.088e-10
```

```
> plot(resultaat)
```



a) Wat is je verwachting t.o.v. de helling van de lijn? Wat is je indruk op basis van het spreidingsdiagram?

b) Wat zijn de nul- en alternatieve hypotheses voor de helling? Toets deze hypotheses aan de hand van de uitvoer.

c) Welke aannames moet je maken om deze toets te gebruiken? Lijkt het erop dat aan deze aannames is voldaan?

d) Lees de waarde van R^2 af in de uitvoer en leg uit hoe dat getal moet worden geïnterpreteerd.

Reflecteren

{ Onderstaande opgaven zijn bedoeld om je te stimuleren kritisch na te denken over de gepresenteerde leerstof. }

■ **Opgave 8.** In een onderzoek waarbij zeer veel Amerikaanse steden betrokken waren (meer dan 1000) heeft een onderzoeker voor een bepaalde periode voor iedere stad (i) het aantal gemelde inbraken X per hoofd van de bevolking, en (ii) het aantal genuttigde hamburgers Y per hoofd van de bevolking bepaald. Hij vond een significante positieve correlatie. Zijn conclusie was dat er een verband bestond tussen X en Y.

a) Wat betekent het als er een correlatiecoëfficiënt positief is?

b) Als men een significante correlatie vindt tussen X en Y, kan men dan zeggen dat er een verband is tussen X en Y?

c) Wat denk je: zou een hamburgerverbod kunnen bijdragen aan het verkleinen van het aantal inbraken? Zo ja, leg uit. Zo nee, hoe kan het dan dat men toch een correlatie vindt?

■ **Opgave 9.** Een gevleugelde uitspraak is: "Correlation does not imply causation." Wat wordt hiermee bedoeld? Als correlatie blijkbaar niet voldoende is – hoe kun je causatie (een oorzakelijk verband) dan *wel* aantonen?

■ **Opgave 10.** Om een waarde van Y te voorspellen op basis van een waarde van X kunnen we een regressieanalyse toepassen.

a) Is het daarvoor nodig dat X en Y correleren?

b) Is het noodzakelijk dat de variatie in Y *veroorzaakt* wordt door de variatie in X?

■ **Opgave 11.** Met behulp van een veldexperiment wil men kijken wat de invloed is van de genetische variatie op een ecosysteem. Een onderzoeker plant groot zeegras (*Zostera marina*) in een groot aantal plots verdeeld over een ondiepe delta van de Baltische Zee. Die plots werden random verdeeld in drie groepen. Op plots van de eerste groep werden jonge spruiten gepoot van maar één genotype. Op plots van de tweede groep werden jonge spruiten van drie verschillende genotypes gepoot en in plots van de derde groep jonge spruiten van zes verschillende genotypen. Per plot werden achttien spruiten gepoot. Aan het eind van het experiment werd per plot het aantal aanwezige spruiten geteld. De gegevens staan in Tabel 4.9.

a) Wanneer gebruik je in het algemeen 1-weg ANOVA en wanneer regressie?

b) Kun je voorbeelden verzinnen waarbij beide methoden geschikt zijn?

c) Welke methode is geschikt voor deze gegevens? Beargumenteer je antwoord.

Tabel 4.9: Ruwe gegevens van veldonderzoek.

Aantal genotypes	*Aantal spruiten*	*Gemiddelde*	*Variantie*
1	11, 14, 21, 27, 28, 30, 32, 36, 38, 49, 61, 71	34.83	321.606
3	20, 35, 36, 41, 46, 47, 52, 53, 58, 67	45.50	176.722
6	31, 45, 45, 47, 48 62, 64, 69, 84, 86	58.10	324.544
Alle spruiten		45.4375	354.89919

Testen

Met behulp van onderstaande opgaven kun je testen of je de stof van dit werkcollege beheerst. Ze zijn bedoeld om je te helpen bij het voorbereiden van het tentamen. Mogelijk kom je er tijdens het werkcollege niet aan toe.

■ **Opgave 12.** Onderzoekers zijn geïnteresseerd in de activiteit van calcium-bindende enzymen in geïsoleerde protoplasten. Nadat eerst een "heat shock"-stimulus is gegeven, wordt deze activiteit gevolgd in de tijd. De onderzoekers willen weten of (en zo ja, hoe) de activiteit van de enzymen over de tijd verandert. Net vóór de stimulus en 1, 2, 4 en 8 uur erna wordt de activiteit bepaald; per tijdstip worden zes monsters gemeten. Dat levert de resultaten op die in Tabel 4.10 zijn weergegeven. Deze gegevens zijn ook in R ingelezen:

tijdstip (uur)	activiteit (a.u.)	
0	3,0	2,0
	3,6	2,6
	2,5	2,8
1	3,3	2,6
	3,1	3,9
	2,7	2,8
2	2,9	3,1
	3,5	3,0
	4,1	3,2
4	4,0	3,8
	4,4	4,6
	3,4	3,9
8	4,5	4,2
	4,8	3,8
	4,7	4,3

Tabel 4.10: Activiteit van calcium-bindende eiwitten op verschillende tijdstippen.

```
> str(protoplasten)
```

```
'data.frame':   30 obs. of  2 variables:
 $ tijdstip  : num  0 0 0 0 0 0 1 1 1 1 ...
 $ activiteit: num  3 3.6 2.5 2 2.6 2.8 3.3 3.1 2.7 2.6 ...
```

a) De onderzoekers besluiten een regressie-analyse toe te passen. De analyse is hieronder ingevoerd, maar er is een getal weggelaten (vervangen door xxxxxxx):

```
> resultaat <- lm(activiteit ~ tijdstip, data = protoplasten)
> anova(resultaat)
```

```
Analysis of Variance Table

Response: activiteit
          Df  Sum Sq Mean Sq F value    Pr(>F)
tijdstip   1 10.2094 10.2094  47.641 1.676e-07 ***
Residuals 28  6.0003  0.2143
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> summary(resultaat)
```

```
Call:
lm(formula = activiteit ~ tijdstip, data = protoplasten)

Residuals:
     Min       1Q   Median       3Q      Max
-0.88458 -0.30646 -0.05958  0.20760  0.89042

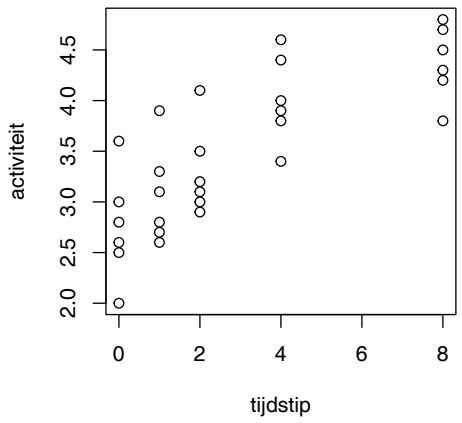
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.88458    0.12320  23.413  < 2e-16 ***
tijdstip     xxxxxxx    xxxxxxx   6.902 1.68e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4629 on 28 degrees of freedom
Multiple R-squared:  0.6298,    Adjusted R-squared:  0.6166
F-statistic: 47.64 on 1 and 28 DF,  p-value: 1.676e-07
```

Welke hypothese kan met de ANOVA-tabel getoetst worden?

b) Is aan de aannames van de regressie-analyse voldaan? Gebruik de beschrijvende statistiek die hieronder wordt gegenereerd; geef aan op welke uitvoer je oordeel gebaseerd is.

```
> plot(protoplasten)
```




```
> summary(protoplasten)
```

```
   tijdstip   activiteit
 Min.   :0   Min.   :2.000
 1st Qu.:1   1st Qu.:2.925
 Median :2   Median :3.450
 Mean   :3   Mean   :3.503
 3rd Qu.:4   3rd Qu.:4.075
 Max.   :8   Max.   :4.800
```

```
> by(protoplasten$activiteit, protoplasten$tijd, sd)
```

```
protoplasten$tijd: 0
[1] 0.5357238
------------------------------------------------------
protoplasten$tijd: 1
[1] 0.4844241
------------------------------------------------------
protoplasten$tijd: 2
[1] 0.4427189
------------------------------------------------------
protoplasten$tijd: 4
[1] 0.4308906
------------------------------------------------------
protoplasten$tijd: 8
[1] 0.3656045
```

```
> sd(protoplasten$activiteit)
```

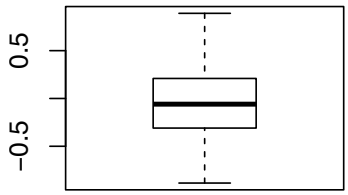
```
[1] 0.7476323
```

```
> sd(protoplasten$tijd)
```

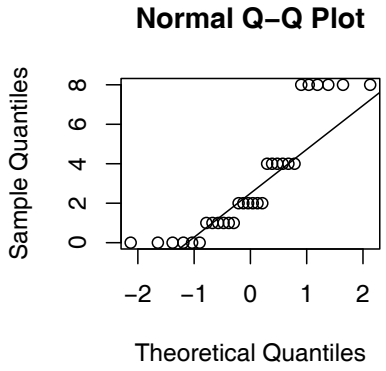
```
[1] 2.87678
```

```
> boxplot(resultaat$residuals, main = "Boxplot van de residuen")
```

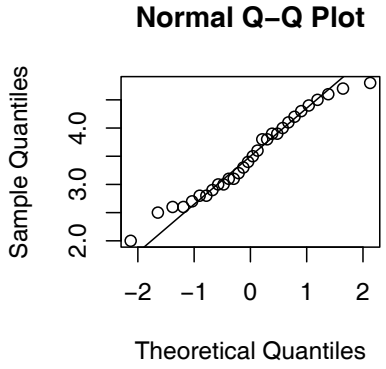
Boxplot van de residuen



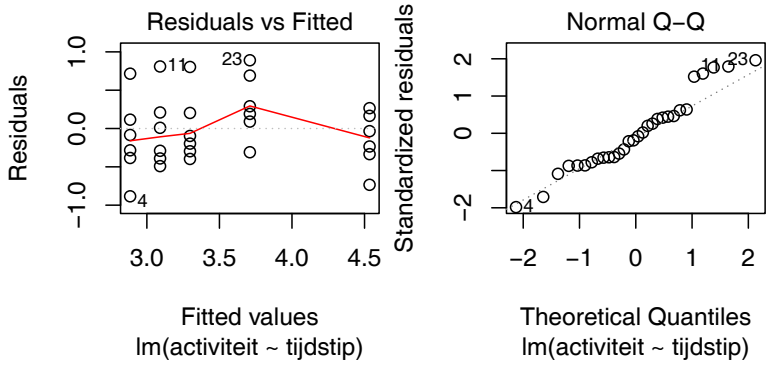

```
> qqnorm(protoplasten$tijdstip); qqline(protoplasten$tijdstip)
```




```
> qqnorm(protoplasten$activiteit); qqline(protoplasten$activiteit)
```




```
> plot(resultaat)
```



```
> leveneTest(activiteit ~ factor(tijdstip), data = protoplasten)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  4  0.1309 0.9697
      25
```

c) Formuleer je conclusies met betrekking tot de in onderdeel a) geformuleerde hypothese.

d) Wat is de correlatiecoëfficiënt r voor de relatie tussen de activiteit en de tijd?

e) Geef de vergelijking van de regressielijn voor deze gegevens. (*Hint:* gebruik je antwoord bij onderdeel d).)

f) Bereken een voorspelling voor de gemiddelde eiwit-activiteit 5 uur na de stimulus.

Week 5: Het ontwerpen van experimenten & Voorbereiding tentamen

Voorbereiding

Voor aanvang van ieder werkcollege:

- Bestudeer de relevante hoofdstukken uit Whitlock & Schluter (zie de Studiewijzer op Blackboard).
- Bestudeer de dia's van het hoorcollege.
- Hou een lijst bij met vragen over de stof, zodat je die op het werkcollege kunt stellen.

Onderwerpen

Het ontwerp van experimenten • onderscheidingsvermogen • de vereiste steekproefomvang berekenen

Verwerken & Oefenen

{ Onderstaande opgaven zijn bedoeld om je te helpen bij het verwerken van de leerstof en het oefenen van vaardigheden. }

■ **Opgave 1.** Om de gemiddelde optische dichtheid van een celcultuur te bepalen doet men vijf onafhankelijke waarnemingen. Men vindt een gemiddelde van 36 MU (Miller Units). Veronderstel dat de populatiestandaardafwijking 3,5 MU is en dat de waarnemingen normaal verdeeld zijn.

a) Bereken het 95%-betrouwbaarheidsinterval voor de gemiddelde optische dichtheid van deze cultuur.

b) De onderzoekers vinden het berekende betrouwbaarheidsinterval te wijd; ze willen de gemiddelde optische dichtheid graag preciezer weten. Men wil het betrouwbaarheidsinterval niet breder hebben dan 4 MU. Om dat voor elkaar te krijgen, willen de onderzoekers het onderzoek herhalen met een grotere steekproef. Welke steekproefgrootte raad jij de onderzoekers aan?

c) Stel dat de breedte van het betrouwbaarheidsinterval niet groter mag zijn dan 2δ. (In andere woorden, we willen een betrouwbaarheidsinterval $\mu = \bar{Y} \pm \delta$, of preciezer.) Neem bovendien aan dat de standaardafwijking σ bekend is. Leid de volgende formule af voor de benodigde steekproefomvang:

$$n \geq \left(\frac{1{,}96\,\sigma}{\delta} \right)^2 .$$

Op pagina 448 van W&S (2^e editie van W&S) of pagina 450 (3^e editie) wordt voor deze situatie een andere formule gepresenteerd. Bespreek het verschil.

d) Hoe groot zou n moeten zijn om de halve lengte δ van het 95%-betrouwbaarheidsinterval gelijk te krijgen aan 1 MU?

e) Hoeveel groter moet de steekproef zijn om de precisie met een factor tien te verbeteren?

■ **Opgave 2.** Maak opgaven 14.3, 14.4, 14.9 uit W&S.

■ **Opgave 3.** De volgende vragen gaan over het begrip "onderscheidingsvermogen" (*power*). We vergelijken steeds twee onderzoeken. Beargumenteer je antwoord!

a) In de eerste studie worden twee behandelingen vergeleken door deze twee behandelingen toe te passen op groepen van 30 patiënten. De tweede studie volgt precies hetzelfde protocol, maar nu met groepen van 20 patiënten. Welke onderzoek heeft een groter onderscheidingsvermogen?

b) In beide studies worden twee behandelingen vergeleken, en beide onderzoeken gebruiken twee groepen van 30 patiënten. Echter, in de eerste studie is de standaardafwijking gelijk aan 6 eenheden, terwijl deze in het tweede onderzoek gelijk is aan 5 eenheden. Welk onderzoek heeft een groter onderscheidingsvermogen?

c) De twee onderzoeken zijn identiek van opzet, en de standaardafwijkingen in beide onderzoeken zijn hetzelfde. Echter, het verwachte effect is in de eerste studie tweemaal zo groot als in de tweede. Welk onderzoek heeft een groter onderscheidingsvermogen?

d) In beide studies worden twee behandelingen vergeleken bij twee groepen patiënten. De standaardafwijkingen zijn steeds gelijk. Het verwachte effect is in de eerste studie tweemaal zo groot als in de tweede. Het vereiste onderscheidingsvermogen is in beide studies gelijk aan 0,90. In welke van de twee onderzoeksopzetten zal het aantal patiënten het grootst moeten zijn?

■ **Opgave 4.** Maak de volgende opgaven uit W&S:

2e editie 14.11, 14.12 en 14.18. Het antwoord van opgave 14.18 staat in dit werkboek.

3e editie 14.11, 14.12 en 14.19. Het antwoord van opgave 14.19 staat in dit werkboek.

Testen

Met behulp van onderstaande opgaven kun je testen of je de stof van dit werkcollege beheerst. Ze zijn bedoeld om je te helpen bij het voorbereiden van het tentamen. Mogelijk kom je er tijdens het werkcollege niet aan toe.

■ **Opgave 5.** Als men het onderscheidingsvermogen ("power") van een toets wil verhogen, dan kan men ervoor kiezen het verwerpingsgebied te vergroten.

a) Juist

b) Onjuist

■ **Opgave 6.** De bloeddruk van mensen wordt meestal uitgedrukt in twee getallen: de *systolische* bloeddruk en de *diastolische* bloeddruk. Om te bepalen of iemand een hoge bloeddruk heeft, wordt vaak gekeken

naar de systolische druk, P_{sys}. In volwassen Nederlandse mannen is P_{sys} grofweg normaal verdeeld, met een gemiddelde van ongeveer 140 mm Hg en een standaarddeviatie van ongeveer 20 mm Hg.

Een onderzoeksgroep onderzoekt of een zeker medicijn effectief is tegen een te hoge bloeddruk. Om dat te testen, werd van 280 volwassen mannen de systolische bloeddruk gemeten (meting 1). Bij 40 van hen was de bloeddruk te hoog (d.w.z., $P_{\text{sys}} > 160$ mm Hg). Deze mensen kregen een behandeling met het medicijn. Tien dagen later werd bij deze 40 mensen weer de systolische bloeddruk gemeten, om te zien of deze door het medicijn was gedaald (meting 2).

a) De bovenstaande proefopzet heeft een aantal zwaarwegende nadelen. Wat zijn die? Hoe zou *jij* dit experiment opzetten? Leg precies uit wat je proefopzet zou zijn, en waarom. Leg ook uit welke statistische toets je zou gebruiken om, zodra de meetgegevens binnen zijn, de onderzoeksvraag te beantwoorden. (*Mits goed onderbouwd kunnen meerdere antwoorden goed zijn.*)

b) Voordat je jouw onderzoek kunt uitvoeren, zul je ook een steekproefgrootte n moeten kiezen. Welke steekproefgrootte denk je nodig te hebben om de onderzoeksvraag te beantwoorden? (**Let op:** Om deze berekening te maken, zul je een aantal parameters moeten kiezen of schatten. Maak een verstandige keuze, en onderbouw die met behulp van de beschrijvende statistiek die hieronder gegeven wordt. (Mits goed onderbouwd kunnen meerdere antwoorden goed zijn.)

```
> str(bloeddruk)
```

```
'data.frame':   280 obs. of  3 variables:
 $ meting.1: int  217 200 193 189 184 183 182 180 177 175 ...
 $ verschil: int  -18 -16 -25 5 -1 -9 -19 -12 -8 0 ...
 $ meting.2: int  199 183 168 194 184 174 163 168 169 175 ...
```

```
> summary(bloeddruk)
```

```
    meting 1        verschil         meting 2
 Min.   : 84.0   Min.   :-25.00   Min.   :144.0
 1st Qu.:130.0   1st Qu.:-17.25   1st Qu.:150.0
 Median :142.0   Median :-13.50   Median :159.5
 Mean   :141.5   Mean   :-11.15   Mean   :161.6
 3rd Qu.:154.0   3rd Qu.: -6.00   3rd Qu.:169.2
 Max.   :217.0   Max.   : 10.00   Max.   :199.0
                 NA's   :240      NA's   :240
```

```
> sd(bloeddruk$"meting 1")
```

```
[1] 19.6589
```

```
> sd(bloeddruk$"meting 2", na.rm = TRUE)
```

```
[1] 14.02176
```

```
> sd(bloeddruk$verschil, na.rm = TRUE)
```

```
[1] 8.453644
```

Uitwerkingen van de werkcollegeopgaven

Hieronder volgen korte uitwerkingen van de opgaven van het werkcollege. Uitwerkingen van de opgaven uit W&S staan achterin dat boek.

Week 1

Opgave 1:

a) numeriek & discreet

b) categoriaal & nominaal

c) categoriaal & ordinaal

d) numeriek & continu

Opgave 2:

a) $3{,}0\,\text{kg} + 3{,}4\,\text{kg} + 4{,}2\,\text{kg} = 10{,}6\,\text{kg}$.

b) Boven de deelstreep worden alle getallen opgeteld (gesommeerd), eronder staat het *aantal* getallen; dat levert dus het gemiddelde op. We krijgen $\bar{Y} = 3{,}53\,\text{kg}$.

c) $3{,}4\,\text{kg} + 4{,}2\,\text{kg} = 7{,}6\,\text{kg}$.

d) Omdat $n = 3$, is het antwoord hetzelfde als bij a).

e) $(3{,}0\,\text{kg})^2 + (3{,}4\,\text{kg})^2 + (4{,}2\,\text{kg})^2 = 38{,}2\,\text{kg}^2$.

f) $(10{,}6\,\text{kg})^2 = 112{,}36\,\text{kg}^2$.

g) Dit is de som van de afwijkingen van het gemiddelde; dat is altijd gelijk aan 0!

h) $(3{,}0\,\text{kg} - 3{,}53\,\text{kg})^2 + (3{,}4\,\text{kg} - 3{,}53\,\text{kg})^2 + (4{,}2\,\text{kg} - 3{,}53\,\text{kg})^2 = 0{,}747\,\text{kg}^2$.

i) Direct invullen:

$$s^2 = \frac{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}{n-1} = \frac{0{,}747\,\text{kg}^2}{2} = 0{,}373\,\text{kg}^2.$$

Met de *shortcut formula*:

$$\frac{\sum_{i=1}^{n}\left(Y_i^2\right) - n\bar{Y}^2}{n-1} = \frac{38{,}2\,\text{kg}^2 - 3 \times (3{,}53333\,\text{kg})^2}{2} = 0{,}373\,\text{kg}^2.$$

Let op! Bij de shortcut formula is het erg belangrijk dat je eerder verkregen resultaten niet tussentijds afrondt. De twee termen in de teller zijn vaak bijna even groot; als je ze van elkaar aftrekt kan het resultaat dan heel erg gevoelig zijn voor tussentijds afronden.

Opgave 3:

Vraag 2.25 uit W&S:

a) Dit is een histogram, maar de regels voor het maken van een histogram zijn niet netjes gevolgd.

b) In een histogram hoort er geen ruimte te zitten tussen de staven. Bovendien is het niet helemaal duidelijk of getallen op de x-as horen bij het midden van de intervallen (staafjes) of bij de grenzen tussen de intervallen.

c) Het meest interessante is misschien het feit dat de histogram zo'n grote spreiding heeft. Dat betekent dat sommige homologe eiwitten van deze kogelvissen vrijwel identiek zijn aan die van mensen, terwijl andere eiwitten enorm verschillen van die van mensen.

d) De histogram is uni-modaal en links-scheef.

e) De modus is 70%. (Waarschijnlijk refereert het getal "70" naar het midden van het interval.)

Opgave 4:

a) Het gemiddelde bij een symmetrische verdeling en de mediaan bij een scheve verdeling.

b) De waarde die het meest voorkomt.

c) Zie W&S of de dia's van het college.

d) (i) L, (ii) L, (iii) L^2, (iv) de variatiecoëfficiënt heeft geen dimensie (is dimensieloos).

Opgave 5:

a) $\bar{Y} = 3{,}18\,\text{in}$, $s^2 = 0{,}377\,\text{in}^2$, $s = 0{,}614\,\text{in}$.

b) $\bar{Y} = 1{,}18\,\text{in}$, $s^2 = 0{,}377\,\text{in}^2$, $s = 0{,}614\,\text{in}$.

c) $\bar{Y} = 8{,}08\,\text{cm}$, $s^2 = 2{,}432\,\text{cm}^2$, $s = 1{,}559\,\text{cm}$.

d) Het gemiddelde van $X = a + bY$ is $a + b\mu$; de variantie $b^2\sigma^2$.

Opgave 6:

a) De bomen in het gebied.

b) De variabele is de boomsoort. Deze is categoriaal & nominaal.

c) Absolute frequenties.

d) Zorg dat aan de richtlijnen uit W&S is voldaan: de staven staan los van elkaar, de y-as begint op 0, en het is voor het oog prettig als de staven van lang naar kort staan gerangschikt.

Opgave 8:

a) De variabele is de hoeveelheid neerslag; deze is numeriek en continu.

b) Sturges' vuistregel suggereert ≈ 7 klassen. De breedte van iedere staaf moet dan ongeveer worden: $(1050 - 427)/7 = 89$. Dat ronden we af naar 90 ten behoeve van de leesbaarheid. De tabel wordt dan:

neerslag (mm/jaar)	frequentie
425–515	1
515–605	6
605–695	7
695–785	17
785–875	12
875–965	5
965–1055	2

c) Zorg dat aan de richtlijnen uit W&S is voldaan: de staven staan aan elkaar vast, de y-as begint op 0.

Opgave 10:

a) Variatiecoëfficiënt voor de lengte: 2,9/86,6 = 0,033. Voor het gewicht: 1,4/12,6 = 0,111. De variatie in gewicht lijkt dus een stuk groter dan de variatie in de lengte.

b) Verschillen in leefstijl hebben een groot effect op het gewicht, en veel minder op lengte. Bij de meisjes van 9 jaar zal daardoor de variatiecoëfficiënt van de lengte niet veel veranderd zijn, terwijl die van het gewicht sterk zal stijgen.

Opgave 11: Een goede beschrijving zou zijn: "Het gewicht van de baby's was gemiddeld 3067 g (mediaan: 3150 g) en de standaardafwijking was 829 g." Vervolgens zou je de punten kunnen plotten of een boxplot kunnen tonen. Later leren we dat het beter is om aan deze beschrijving een betrouwbaarheidsinterval toe te voegen.

Opgave 13:

a) Een voorbeeld is een classificatie van de historische waarde van archeologische vondsten op een schaal van 1 tot 5.

b) Stel dat je de tijdsduur van een bepaald proces meet, maar je kunt om praktische redenen maar 1 keer per uur meten. Dan zal de tijdsduur – op zich een continue variabele – alleen discrete waarden aannemen (1 uur, 2 uur, …). Hoe grover de precisie van je meting, hoe meer je geneigd zou zijn om de gegevens als discreet op te vatten.

c) Of je bepaalde klassen als natuurlijk geordend beschouwt, hangt erg af van de focus van je onderzoek. Bedrijfsnamen hebben bijvoorbeeld een alfabetische ordening. Meestal is die volledig irrelevant en zou je de bedrijfsnaam als nominale variabele beschouwen. Maar wat als je wilt onderzoeken of bedrijven bewust namen kiezen die hoog in gealfabetiseerde lijsten verschijnen (zoals bedrijvengidsen)?

Opgave 14: De mediaan zou als schoolcijfer een aantal voordelen hebben, omdat deze minder gevoelig is voor uitbijters. Als je het hele jaar goede cijfers hebt gehaald, maar één keer door omstandigheden niet hebt kunnen leren voor een proefwerk, dan zou die ene keer misschien niet al te zwaar hoeven meetellen op je rapport. Maar "ieder voordeel heb zijn nadeel". Wat zou er gebeuren met het rapportcijfer als een leerling besluit alleen de eerste helft van het jaar zijn best te doen?

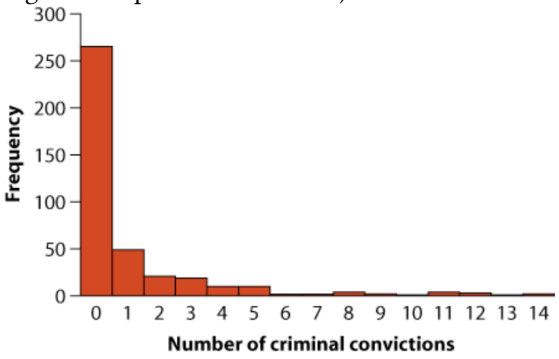
Opgave 15:

Opgave 1.14 (2e editie) of 1.15 (3e editie) uit W&S:

a) numeriek & discreet.
b) numeriek & continu.
c) numeriek & continu.
d) numeriek & continu.
e) categoriaal & ordinaal.
f) numeriek & continu.
g) categoriaal & nominaal.
h) numeriek & discreet.
i) categoriaal & nominaal.

Opgave 2.22 uit W&S:

a) Frequentietabel.
b) Slechts één: het aantal veroordelingen.
c) 21.
d) 265 van de 395 jongens, dus een fractie 0,67.
e) De beste manier om de frequentietabel van een numerieke variabele te visualiseren is met een histogram. (Eventueel zou je een cumulatieve frequentieverdeling kunnen plotten – zie W&S.)



f) De verdeling is unimodaal en rechts-scheef. De modus is 0.
g) Nee, het ging om zes scholen die allemaal dicht bij het onderzoeksbureau lagen; dat is geen willekeurige steekproef van de populatie van Britse jongens.

Opgave 16: a.

Opgave 17: b.

Opgave 18: b.

Opgave 19: d.

Opgave 20: d.

Opgave 21: b.

Week 2

Opgave 3:

a) 1,645

b) 0,265

c) -1,645

d) 0,43

e) 1,96

f) 1,645

Opgave 4:

a) Zie de dia's van het college.

b) (i) s, (ii) s, (iii) $\mathrm{SE}_{\bar{Y}}$, (iv) $\sigma_{\bar{Y}}$, (v) σ^2, (vi) s^2, (vii) σ. In het boek worden zowel $\sigma_{\bar{Y}}$ als $\mathrm{SE}_{\bar{Y}}$ de standaardfout genoemd. Dat is verwarrend, maar in de praktijk leidt dat zelden tot problemen. Onthoud: $\sigma_{\bar{Y}}$ is de standaarddeviatie van de steekproefverdeling van het gemiddelde, en $\mathrm{SE}_{\bar{Y}}$ is de schatter daarvan. (In de literatuur wordt in plaats van $\mathrm{SE}_{\bar{Y}}$ vaak de afkorting SEM gebruikt, voor Standard Error of the Mean.)

Opgave 5:

a) onjuist

b) juist

c) juist

d) onjuist

e) onjuist

f) juist

Opgave 6:

a) Gemiddelde verschil is $\bar{d} = 1{,}19\,\mathrm{cm/s}$; standaardafwijking is $s_d = 1{,}07$; standaardfout is $\mathrm{SE}_{\bar{d}} = s_d/\sqrt{16} = 0{,}27\,\mathrm{cm/s}$. Gebruik $t_{0{,}05(2);15} = 2{,}13$. Dan is het 95%-betrouwbaarheidsinterval van het gemiddelde verschil: $(1{,}19 \pm 2{,}13 \times 0{,}27)\,\mathrm{cm/s}$, oftewel $[0{,}61\,\mathrm{cm/s}; 1{,}76\,\mathrm{cm/s}]$. Maar let op: aangezien de waarnemingen niet normaal verdeeld zijn, mag je dit resultaat eigenlijk niet vertrouwen!

b) Ja, want 0 valt niet in het betrouwbaarheidsinterval van het gemiddelde verschil. Maar nogmaals: aangezien de waarnemingen niet normaal verdeeld zijn, mag je dit resultaat eigenlijk niet vertrouwen!

Opgave 7: In onderdeel e)van opgave 4.7 van W&S wordt gevraagd het 95%-betrouwbaarheidsinterval te berekenen met behulp van t-statistiek. Dat levert op:

$$\begin{aligned}\mu =& \bar{Y} \pm t_{0{,}05(2)34}\left(\frac{s}{\sqrt{n}}\right)\\ =& 95{,}94\,\mathrm{ms} \pm 2{,}03 \times \left(\frac{10{,}9945\,\mathrm{ms}}{\sqrt{35}}\right)\\ =& (95{,}94 \pm 3{,}77)\,\mathrm{ms}.\end{aligned}$$

Opgave 8: Je kunt het gemiddelde direct aflezen uit de uitvoer van de t-toets ("`mean of x`"); deze is gelijk aan 2,2. Ook het 95%-betrouwbaarheidsinterval is daar direct te vinden: $[1{,}391; 3{,}009]$. De standaarddeviatie bereken je uit de variantie die gegeven is: $s = \sqrt{0.425} = 0.652$. De standaardfout van het gemiddelde volgt dan als $\mathrm{SE}_{\bar{Y}} = s/\sqrt{n} = 0.292$.

Opgave 10:

a) Dan verschuift het gehele interval 20 eenheden, maar de breedte blijft gelijk.

b) Dan worden de linkergrens en de rechtergrens met 10 vermenigvuldigd; daardoor verschuift het interval en wordt 10 keer zo breed.

c) Iedere waarneming met 15% verhogen is hetzelfde als vermenigvuldigen met 1,15. Dan verschuift het interval en wordt 1,15 keer zo breed.

Opgave 12: Zeker niet. Het is in de praktijk heel erg lastig om een aselecte steekproef uit te voeren. Hoe zou jij aselect 10 fruitvliegen uit de Nederlandse populatie selecteren? Het is essentieel om er altijd naar te streven je steekproeven zo aselect mogelijk samen te stellen – maar in de praktijk is de ideale steekproef meestal een illusie.

Opgave 13: Kort gezegd: om historische redenen. Er is niets speciaals of magisch aan het 95% betrouwbaarheidsinterval. In feite zou je in elke situatie opnieuw moeten beslissen welk interval voor jouw doeleinden het meest geschikt is. In de praktijk gebeurt dat zelden en wordt bijna altijd het 95% betrouwbaarheidsinterval gepresenteerd – simpelweg uit gewoonte.

Opgave 14: Zoals we geleerd hebben, is het strikt genomen alleen noodzakelijk dat de verdeling van het *steekproefgemiddelde* normaal verdeeld is (en niet zozeer de verdeling van de variabele zelf in de populatie). Bij grote steekproeven zit dat meestal wel goed, als gevolg van de Centrale Limietstelling. Bij kleine steekproeven is er wel een probleem. In sommige gevallen kun je de gegevens transformeren, in de hoop dat ze na transformatie

wel normaal verdeeld zijn; we zullen het daar later meer over hebben. Als dat niet lukt, dan rest je geen andere optie dan in plaats van een betrouwbaarheidsinterval alleen de standaardfout van het gemiddelde te rapporteren. Die zegt wel iets, maar lang niet zoveel als het betrouwbaarheidsinterval.

Opgave 15: Veel variabelen in de natuur worden beïnvloed door een groot aantal factoren. Ieder van die factoren variëert per individu en draagt een steentje bij aan de variatie van de variabele. Wanneer dat het geval is, dan is het een wiskundig feit dat de variabele bij benadering normaal verdeeld zal zijn. Dit is in feite het gevolg van een algemene versie van de Centrale Limietstelling. In de statistiek plukken we daar de vruchten van. Veel methoden zijn gebaseerd op de normale verdeling, en die methoden zouden niet erg nuttig zijn als die verdeling niet vaak zou voorkomen.

Opgave 16: b.

Opgave 17: b.

Opgave 18: a.

Opgave 19: b.

Opgave 20: d.

Opgave 21: c.

Opgave 22: a.

Opgave 23: c.

Week 3

Opgave 2:

a) Het gemiddelde is 51,7 g. De variantie kun je niet berekenen: daar heb je tenminste twee waarnemingen voor nodig! Dat is ook eigenlijk wel logisch. De variantie van een steekproef is immers een schatter voor de variantie van de populatie, en een enkele waarneming bevat geen informatie over de spreiding in die populatie.

b) H_0: $\mu = 52$ g; H_A: $\mu \neq 52$ g. We willen een t-test voor één steekproef uitvoeren. De toetsingsgrootheid is

$$t = \frac{\bar{Y} - \mu_0}{\mathrm{SE}_{\bar{Y}}},$$

waar $\mu_0 = 52$ g staat voor het gemiddelde onder de nulhypothese. De toetsingsgrootheid t is verdeeld volgens de t-verdeling met $n - 1 = 3$ vrijheidsgraden. De kritieke waarde is $t_{0,05(2)3} = 3{,}18$.

c) Om de toets uit te voeren, vullen we de formule hierboven in. We vinden $\bar{Y} = 50{,}575$ g en $\mathrm{SE}_{\bar{Y}} = s/\sqrt{n} = 1{,}615/2 = 0{,}808$; dat resulteert in:

$$t = \frac{50{,}575 - 52}{0{,}808} = -1{,}764.$$

We vinden dat $|t| < t_{0,05(2)3} = 3{,}18$; t ligt niet in het verwerpingsgebied. Daarom kunnen we H_0 op basis van deze waarnemingen niet verwerpen. Vooralsnog is er dus geen aanleiding om de poelier te wantrouwen.

d) De waarde van $|t|$ die we gevonden hebben ($|t| = 1{,}764$) ligt tussen $t_{0,1(2)3}$ en $t_{0,2(2)3}$ in. We concluderen daarom dat $0{,}1 < P < 0{,}2$. Preciezer kunnen we de schatting met behulp van deze tabel niet maken.

Opgave 3:

a) De aannames zijn: (i) de steekproef is aselect, (ii) de verschillen tussen de paren komen uit een normaalverdeelde populatie. Let op: er is hier geen aanname over de varianties of de verdeling van de "2 groepen", want alleen de *verschillen* binnen paren zijn van belang! Je kunt niet aan de gegevens zien of aan voorwaarde (i) is voldaan; dat moet je d.m.v. een zorgvuldig experimenteel ontwerp bewerkstelligen. Voorwaarde (ii) kan worden gecontroleerd door de verschillen te analyseren. Je krijgt een aardige indruk als je naar een boxplot kijkt. Bovendien kun je een een "normality test" uitvoeren in R; die vertelt of de verdeling van je waarnemingen significant afwijkt van een normale verdeling. Maar het best is om een *normal probability plot* (zie W&S) of *Q–Q-plot* te maken en die visueel te beoordelen.

b) De aannames zijn: (i) beide steekproeven zijn aselect, (ii) beide steekproeven komen uit een normaalverdeelde populatie, (iii) de populatievarianties van beide groepen zijn gelijk. Of aan voorwaarde (i) is voldaan kan niet op basis van de gegevens worden gecontroleerd; dat moet door de experimentele proefopzet worden gewaarborgd. Voorwaarde (ii) kan worden gecontroleerd door de twee steekproeven te analyseren. Je krijgt een aardige indruk door naar boxplots van beide steekproeven te kijken. Bovendien kun je *normality tests* uitvoeren in R; die vertellen je of de verdelingen significant afwijken van normale verdelingen. Maar het best is weer om *normal probability plots* of Q–Q-plots te maken en die visueel te beoordelen. Voorwaarde (iii) kan worden gecontroleerd

door de steekproefvarianties uit te rekenen en te vergelijken; door *side-by-side* boxplots te tekenen; en eventueel door in R Levene's toets toe te passen.

c) Bij de t-toets voor twee steekproeven wordt het gemiddelde van de twee steekproeven met elkaar vergeleken. Bij de t-toets voor gepaarde waarnemingen wordt het gemiddelde *verschil* tussen twee gepaarde steekproeven vergeleken met een veronderstelde waarde (meestal 0).

d) De t-toets voor gepaarde waarnemingen is niets anders dan een t-toets voor één steekproef, maar dan toegepast op de verschillen binnen paren.

Opgave 5:

a) Als er aan de uitvoer iets niet duidelijk is, stel dan vragen aan een assistent of docent!

b) Het gaat om een t-toets voor één steekproef. Aan de functie `t.test()` is de optie `mu = 90` meegegeven; dit betekent dat de nulhypothese en alternatieve hypothese voor de uitgevoerde test als volgt waren:

$$H_0: \quad \mu = 90 \text{ mm Hg.}$$
$$H_A: \quad \mu \neq 90 \text{ mm Hg.}$$

De aannames zijn dat de steekproef aselect is en dat de bloeddruk normaal verdeeld is in de populatie.

c) De toetsingsgrootheid is $t = -0{,}613$; de overschrijdingskans $P = 0{,}543$. We kunnen de hypothese niet verwerpen omdat $P > 0{,}05$. Een andere manier om dat te zien is door de kritieke waarde op te zoeken in Tabel C van W&S: $t_{0{,}05(2)49} = 2{,}01 > |t|$, dus t ligt niet in het verwerpingsgebied.

d) Je kunt dit uitlezen uit de uitvoer:

$$86{,}32 \text{ mm Hg} < \mu < 91{,}96 \text{ mm Hg},$$

oftewel, het betrouwbaarheidsinterval is [86,32 mm Hg; 91,96 mm Hg].

e) De testwaarde van 90 mm Hg valt binnen het 95%-betrouwbaarheidsinterval uit onderdeel d); dat betekent dat het gevonden gemiddelde niet significant afwijkt van de testwaarde (gegeven $\alpha = 0{,}05$). Dat is inderdaad wat we vonden in onderdeel c).

Opgave 7:

a) Er wordt een t-toets voor 2 onafhankelijke steekproeven uitgevoerd. Als er aan de code of uitvoer iets niet duidelijk is, stel dan vragen aan een assistent of docent.

b) H_0: Er is geen verschil in het gemiddelde gewicht van de twee populaties kuikens. H_A: Er is wel een verschil in het gemiddelde gewicht van de twee populaties kuikens.

c) Aflezen: het verschil van de gemiddelden is 69,685 g − 67,513 = 2,171. Dit is een "puntschatting"; dat wil zeggen, een schatting zonder een maat van precisie.

d) Door die optie te gebruiken, nemen we aan dat de variantie van het gewicht gelijk is in beide populaties. Hierdoor voert R een standaard t-toets uit voor twee onafhankelijke steekproeven. Als je deze optie niet gebruikt, voert R de zogenaamde Welch t-toets uit (zie W&S) die de aanname van gelijke varianties niet maakt.

e) Aflezen: $[-4{,}072 \text{ g}; -0{,}271 \text{ g}]$.

f) Ja. De standaardafwijkingen van de steekproeven liggen dicht bij elkaar. Bovendien is Levene's toets uitgevoerd. Deze toets heeft als nulhypothese dat de varianties gelijk zijn. Het resultaat van de toets is $P = 0{,}7325$; dat betekent dat de nulhypothese niet verworpen kan worden en er dus geen reden is om aan de gelijkheid van de varianties te twijfelen.

g) (i) We lezen af: $P = 0{,}02664 < \alpha$, dus de nulhypothese kan worden verworpen. Dezelfde conclusie volgt door af te lezen dat $t = -2{,}34$; de kritieke waarde $t_{0{,}05(2)28} = 2{,}05$ (opzoeken in Tabel C van W&S) is duidelijk kleiner dan $|t|$ en dus wordt H_0 verworpen. (iii) Het betrouwbaarheidsinterval uit onderdeel e) omvat het getal 0 niet, en dus wijkt het verschil tussen de gemiddelden van de groepen significant af van 0. De nulhypotheses wordt dus wederom verworpen.

Opgave 8:

a) Het gemiddelde verschil tussen de pH 's avonds en 's ochtends is af te lezen bij `mean of the difference`: −0,43. Het betrouwbaarheidsinterval van die schatting kan ook worden afgelezen: $[-0{,}59; -0{,}28]$. Anders gezegd: de beste schatting is $-0{,}43 \pm 0{,}16$ (95% betrouwbaarheidsinterval).

b) H_0 : Het verschil tussen de pH 's ochtends en 's avonds is gemiddeld 0. H_A : Het verschil tussen de pH 's ochtends en 's avonds is gemiddeld geen 0. Om dit te testen hebben we een gepaarde t-toets nodig, want we hebben de pH bij iedere vijver twee keer gemeten ('s ochtends en 's avonds) en zijn geïnteresseerd in de *verschillen* tussen die herhaalde metingen (en dus niet zozeer in verschilllen tussen vijvers onderling). Aan het 95%-betrouwbaarheidsinterval konden we al zien dat het verschil significant is (bij $\alpha = 0{,}05$). Dit zien we ook aan de overschrijdingskans uit de uitvoer: $P = 0{,}0002$. Tenslotte concluderen we hetzelfde op basis van de toetsingsgrootheid:

$$|t| = 6{,}389 > t_{0{,}05(2)8} = 2{,}31.$$

Dit laat zien dat t in het verwerpingsgebied ligt. (De kritieke waarde zoek je op in Tabel C van W&S.)

Opgave 10:

a) We gaan er van uit dat men de herten in dit gebied kent. Uit de populatie mannelijke volwassen herten wordt een aselecte steekproef genomen van 24 herten.

Met behulp van de computer of door loting worden deze willekeurig verdeeld over de vier maanden. Vervolgens wordt de hoeveelheid voedsel dat elk van de geselecteerde herten consumeert gedurende de toegewezen maand bijgehouden. (Dat laatste is trouwens niet gemakkelijk – maar dat is niet zozeer een statistisch probleem.)

b) H_0 : De gemiddelde consumptie is in iedere maand hetzelfde. H_A : De gemiddelde consumptie is niet in alle maanden hetzelfde. (Oftewel: tenminste één maand wijkt af.)

c) We gaan een ANOVA uitvoeren. Dit is een flink rekenwerk; voor het begrip doen we doen dit één keer handmatig, daarna zul je altijd de computer gebruiken (bijv. R). We rekenen eerst de kwadratensommen uit:

$$\begin{aligned}
\mathrm{SS}_{\text{error}} &= \sum_i (n_i - 1)s_i^2 \\
&= 4 \times 0{,}1304^2 + 5 \times 0{,}1751^2 + \ldots \\
&= 0{,}627\,(\text{kg/dag})^2, \\
\mathrm{SS}_{\text{groups}} &= \sum_i n_i \left(\bar{Y}_i - \bar{Y}\right)^2 \\
&= 5 \times (4{,}820 - 4{,}741)^2 + \ldots \\
&= 2{,}308\,(\text{kg/dag})^2, \\
\mathrm{SS}_{\text{total}} &= \mathrm{SS}_{\text{error}} + \mathrm{SS}_{\text{groups}} = 2{,}933\,(\text{kg/dag})^2.
\end{aligned}$$

($\mathrm{SS}_{\text{total}}$ hebben we voor de berekeningen hieronder eigenlijk niet nodig.) Daaruit kunnen we de *mean squares* uitrekenen:

$$\begin{aligned}
\mathrm{MS}_{\text{error}} &= \frac{\mathrm{SS}_{\text{error}}}{N-k} \\
&= \frac{0{,}627}{18} = 0{,}035\,(\text{kg/dag})^2. \\
\mathrm{MS}_{\text{groups}} &= \frac{\mathrm{SS}_{\text{groups}}}{k-1} \\
&= \frac{2{,}307}{4-1} = 0{,}769\,(\text{kg/dag})^2.
\end{aligned}$$

Dan is de toetsingsgrootheid gelijk aan

$$F = \frac{\mathrm{MS}_{\text{groups}}}{\mathrm{MS}_{\text{error}}} = \frac{0{,}769}{0{,}035} = 22{,}1.$$

Nu zoeken we de kritieke waarde op; dat is $F_{0{,}05;3,18} = 3{,}16$. Omdat $F > F_{0{,}05;3,18}$ verwerpen we H_0. Als alternatief kunnen we de overschrijdingskans schatten met Tabel D uit W&S; dat levert op dat $P < 0.01$. In beide gevallen concluderen we dat niet alle gemiddelden hetzelfde zijn.

d) De aannames van ANOVA zijn altijd hetzelfde: de steekproeven zijn aselect, de waarnemingen uit alle groepen zijn normaal verdeeld (*normaliteit*), onafhankelijk, en de populatievarianties van alle groepen zijn hetzelfde (*homogeniteit*). Anders gezegd: de steekproeven zijn aselect, en de *residuen* zijn onderling onafhankelijk en allemaal uit dezelfde normale verdeling getrokken.

e) Post-hoc-toetsen zijn zinvol als de H_0 van de ANOVA wordt verworpen. Dat is hier het geval.

Opgave 12:

a) Het aantal vrijheidsgraden van de residuen is $\mathrm{df}_{\text{error}} = N - k$. In de ANOVA-tabel lezen we dat $\mathrm{df}_{\text{error}} = 72$. Het aantal groepen is $k = 3$. Dat wil zeggen dat $N = 75$. Gegeven dat er drie groepen zijn van gelijke grootte, geeft dat 25 vrouwtjes per groep.

b) De eerste aanname is dat de variabele in iedere groep normaal verdeeld is. Om die aanname te controleren kun de boxplots gebruiken, en daarnaast de QQ-plot van de residuen. De boxplots zien er redelijk symmetrisch en uit en de QQ-plot toont een nette rechte lijn. De tweede aanname is dat de variantie van iedere groep gelijk is. Dat kan worden gecontroleerd door de hoogte van de boxplots te vergelijken en door de standaardafwijkingen van de groepen rechtstreeks te vergelijken. Ook kan gebruik gemaakt worden van Levene's test; die geeft geen significant resultaat. De data voldoen niet perfect aan de voorwaarden, maar ANOVA is redelijk robuust, zeker als de groepen gebalanceerd zijn (allen even groot) en niet al te klein; dat zit hier wel goed.

c) $H_0 : \mu_1 = \mu_2 = \mu_3$
H_A : tenminste één van de groepsgemiddelden wijkt af.

Je leest uit de tabel af dat de overschrijdingskans gelijk is aan $P = 0{,}01224$. Dit is kleiner dan $\alpha = 0{,}05$, dus H_0 wordt verworpen.

d) In de uitvoer van de `summary()` functie worden de gemiddelden van alle groepen vergeleken met die van de controlegroep. De P-waarden die daar worden afgelezen, zijn nog niet gecorrigeerd. Omdat er tussen drie groepen ook drie paarsgewijze vergelijkingen kunnen worden uitgevoerd, moeten we alle P-waarden met 3 vermenigvuldigen om Bonferronigecorrigeerde waarden te verkrijgen. De P-waarde voor de vergelijking tussen de resistente lijn en de controle-lijn wordt dan $P = 0{,}00311 \times 3 = 0{,}00933$. Dat is nog steeds een stuk kleiner dan $\alpha = 0{,}05$, en dus is het verschil significant.

Opgave 14: Als we ervan uit gaan dat alle onderzochte nulhypotheses eigenlijk juist zijn, dan heeft elke onderzoeksgroep een kans van $\alpha = 0{,}05$ om alsnog de nulhypothese te verwerpen (Type I fout). Naar verwachting gebeurt dat dus bij 1 van de 20 onderzoeken (want $20 \times 0{,}05 = 1$). Wetenschappelijke tijdschriften zullen niet erg geïnteresseerd zijn in de (gemiddeld) 19 onderzoeken die *geen* significante aanwijzing vinden voor een toch

al vergezochte alternatieve hypothese. Je leest daarom waarschijnlijk alleen de resultaten terug van het ene onderzoek (naar verwachting) waarbij toevallig een fout van Type I optrad. Waarschijnlijk worden de resultaten dan gepresenteerd als *onverwacht* bewijs voor een *verrassende* hypothese. Bij het lezen van welk tijdschrift dan ook is het dus raadzaam er een sceptische houding op na te houden.

Opgave 15: Deze redenering lijkt erg aannemelijk, maar er zijn grote problemen mee. Natuurlijk: een mens is geen muis, en dus zijn de uitkomsten van dierproeven niet zomaar van toepassing op de mens. Maar een subtieler punt is: als er geen significant verschil wordt gevonden tussen de twee groepen, dan kan dat ook komen doordat er een te kleine steekproef is gebruikt! Je hebt in een dergelijke situatie veel meer aan een betrouwbaarheidsinterval voor het verschil tussen de groepen; zo'n interval vertelt (met 95% betrouwbaarheid) hoe groot of klein het effect op basis van de huidige gegevens kan zijn. Als zo'n betrouwbaarheidsinterval heel breed is, dan kan het zo zijn dat het 0 omvat (en de H_0 dus niet kan worden verworpen) terwijl tegelijkertijd nog zeker niet is uitgesloten dat er een serieus kankerverwekkend effect is.

Opgave 16: d.

Opgave 17: a.

Opgave 18: b.

Opgave 19: b.

Opgave 20: a.

Opgave 21:

a) Gegeven (zie de uitvoer van `summary()` zijn het gemiddelde (37,17 °C), de steekproefomvang ($n = 25$), en de standaarddeviatie ($s = 0{,}950108$ °C). Tabel C van W&S laat zien dat $t_{0{,}05(2)24} = 2{,}06$. Het betrouwbaarheidsinterval is dan:

$$\mu = 37{,}17 \pm 2{,}06 \times \left(\frac{0{,}950}{\sqrt{25}}\right) = 37,17 \pm 0{,}39^{\circ}\text{C}.$$

b) De correcte toets is de gepaarde t-test uit de tweede analyse. De overschrijdingskans en het aantal vrijheidsgraden kunnen niet worden afgelezen, maar de toetsingsgrootheid wel: $|t| = 2{,}352$. Het aantal vrijheidsgraden is $n - 1 = 24$. In Tabel C van W&S zien we dan dat $0{,}02 < P < 0{,}05$.

c) De muizen zijn afkomstig uit een aselecte steekproef en de verschillen tussen de gepaarde waarnemingen voor en na moeten normaal verdeeld zijn.

Opgave 22:

a) In totaal worden in dit experiment 60 zaailingen gebruikt. Deze moeten aselect geselecteerd worden uit alle beschikbare zaailingen. Ze worden vervolgens willekeurig verdeeld over de vijf behandelingsgroepen (bijvoorbeeld door loting). In het experiment moet er voor gezorgd worden dat de planten in aparte, vergelijkbare ruimtes staan (hiermee voorkom je menging van de behandelingen).

b) Aanname 1, dat de variabele in alle groepen normaal verdeeld is, kun je controleren door de boxplots te bekijken. Die zien er niet al te scheef uit. Bovendien kan met behulp van de "QQ-plot van de residuen" gecontroleerd worden of de *residuen* normaal verdeeld zijn. Dit ziet er goed uit. Let op: Als alle groepen normaal verdeeld zijn met dezelfde variantie, dan komen alle residuen uit dezelfde normale verdeling. Daarom kunnen de residuen van alle groepen worden samengevoegd en verwerkt tot één Q–Q-plot. Dit geldt niet voor de waarnemingen zelf: deze komen uit groepen met verschillende gemiddelden en daardoor verschillende normale verdelingen.

   Aanname 2 is dat de variantie in iedere groep gelijk is. Aan de beschrijvende statistiek is te zien dat de standaarddeviaties van de 5 groepen niet al te veel van elkaar verschillen; ook de *side-by-side* boxplots geven geen reden om te twijfelen aan gelijke varianties. Met behulp van Levene's test wordt de homogeniteit formeel getoetst. De overschrijdingskans van deze toets is $P = 0{,}3562$, dus er is geen aanwijzing voor inhomogeniteit van de groepsvarianties.

   Op basis van deze informatie is het verantwoord een ANOVA uit te voeren.

c) H_0: Het gemiddelde van de variabele is in alle groepen gelijk.
   H_A: Het gemiddelde van de variabele is niet in alle groepen hetzelfde.

   De overschrijdingskans uit de ANOVA-tabel is $P = 0{,}0058$. H_0 wordt dus verworpen; er is verschil in de groepsgemiddelden aangetoond.

d) De onderzoekers zouden een correctie moeten uitvoeren voor *multiple testing*, zoals Bonferroni of Tukey–Kremer. Met de hand kunnen we een Bonferroni-correctie toepassen. Er zijn 5 groepen en dus 10 mogelijke vergelijkingen. De gecorrigeerde P-waarde voor de vergelijking tussen groep 4 en de controlegroep wordt dan $P = 0{,}00791 \times 10 = 0{,}0791$. Dit is groter dan $\alpha = 0{,}05$ en dus is het verschil niet significant. De conclusie van de onderzoekers is dus discutabel. Wellicht zou de Tukey–Kremer-methode wel een significante P-waarde opleveren, aangezien de Bonferroni-methode conservatiever is. Hoe dan ook is het resultaat niet erg overtuigend.

Week 4

Opgave 1: Het probleem is: door twee punten kan altijd een rechte lijn worden getrokken. Als die lijn stijgt, is de correlatie gelijk aan 1; daalt deze, dan is de correlatie -1; en als de lijn precies horizontaal loopt, dan is de correlatie 0. De onderzoeker heeft dus geen gelijk: het aantal waarnemingen is te klein om ook maar enige conclusie te trekken.

Opgave 2:

a) De correlatiecoëfficiënt is dimensieloos. De covariantie heeft dimensie $[X] \times [Y]$.

b) Spearman's correlatiecoëfficiënt wordt berekend uit de rangnummers van de gegevens; Pearson's correlatiecoëfficiënt wordt berekend uit de gegevens zelf. Daardoor is Spearman's correlatiecoëfficiënt een maat voor een *monotoon stijgend of dalend* verband, terwijl Pearson's correlatiecoëfficiënt een maat is voor een *lineair* verband.

c) Zie W&S.

d) De richtingscoëfficiënt van de regressielijn geeft aan hoeveel het gemiddelde van Y verandert als X met één eenheid wordt verhoogd.

e) De correlatie tussen Y en X is een maat voor de lineaire relatie tussen die twee variabelen. De regressie van Y op X is de rechte lijn die voor iedere waarde van X (binnen een bepaald domein) aangeeft wat de beste voorspelling is voor het gemiddelde van Y, aangenomen dat X en Y een lineaire relatie hebben.

f) Ja, er is een relatie, maar ze zijn niet hetzelfde. Vergelijk de formules voor de richtingscoëfficiënt van de regressielijn en de correlatiecoëfficiënt maar eens; dan zie je dat $r = b\,(s_X/s_Y)$. Als de richtingscoëfficiënt positief is, dan is de correlatiecoëfficiënt dat ook, en *vice versa.*

Opgave 5:

a) Je zou verwachten dat zware krabben ook zware kieuwen hebben; een positief verband ligt voor de hand.

b) In het spreidingsdiagram is inderdaad een positief verband te herkennen.

c) Lees af: $r = 0{,}77$.

d) H_0: Er is geen correlatie tussen het gewicht van een krab en het gewicht van zijn kieuwen. ($\rho = 0$) H_A: Er is een correlatie tussen het gewicht van een krab en het gewicht van zijn kieuwen. ($\rho \neq 0$)

e) Lees af: $P = 0{,}005239$.

f) We nemen aan dat het om een willekeurige steekproef gaat. Dat kunnen we niet controleren aan de hand van de gegevens, maar moet door de proefopzet worden gewaarborgd. Bovendien nemen we aan dat de gegeven bivariaat normaal verdeeld zijn. Er zijn relatief weinig datapunen, dus veel kunnen we hier niet over zeggen, maar het spreidingsdiagram heeft wel grofweg de juiste ovale vorm.

g) $P = 0{,}005239$ is kleiner dan $\alpha = 0{,}05$, dus er is een significant positief verband tussen kieuw- en lichaamsgewicht.

Opgave 6:

a) Aflezen van a (intercept) en b (regressiecoefficient bij `vitamineniveau` uit de **`summary`**-tabel levert op:

$$\hat{Y} = 16{,}746 + 1{,}316X.$$

b) $H_0 : \beta = 0$. $H_A : \beta \neq 0$. We lezen in de ANOVA-tabel dat $P = 0{,}017$. Dat is kleiner dan $\alpha = 0{,}05$, dus we verwerpen H_0; de regressiecoefficient is significant groter dan 0. Dezelfde overschrijdingskans kan overigens ook worden afgelezen uit de tabel in de uitvoer van de functie **`summary()`**.

c) Vul in de vergelijking hierboven $X = 25$ in; dat levert $\hat{Y} = 49{,}6$ op. Dat is de voorspelling voor de gemiddelde waarde van Y bij $X = 25$. Eigenlijk zouden we hier een betrouwbaarheidsinterval bij willen geven! Die kan met de hand of met R berekend worden, maar dat voert voor deze cursus te ver. De formule staat wel in W&S, Hoofdstuk 17.

d) Het vitamineniveau van de steekproef varieert tussen 3 en 20. Voorspellingen buiten dit domein zijn extrapolaties. Dit is altijd gevaarlijk: je weet meestal niet of de regressielijn ook buiten zijn domein geldig is.

Opgave 7:

a) Je verwacht dat de absorptie toeneemt met de concentratie van het eiwit, en dus dat de helling positief is. Het spreidingsdiagram bevestigt dit en laat een zeer sterk lineair verband zien.

b) Hypothesen:
$H_0 : \beta = 0$; $H_A : \beta \neq 0$. Aflezen overschrijdingskans: $P = 6{,}1 \times 10^{-10}$. De nulhypothese wordt verworpen, de helling verschilt significant van nul. De gevonden richtingscoëfficiënt is inderdaad positief.

c) Voor de lineaire regressieanalyse moeten we (naast een willekeurige steekproef) als eerste aannemen dat er een lineair verband is. Dat kunnen we controleren door naar het spreidingsdiagram te kijken (ziet er als een rechte lijn uit) en door naar de residuenplot te

kijken (de rode lijn loopt netjes horizontaal en de residuen vertonen geen structuur). Ook nemen we aan dat de residuen normaal verdeeld zijn bij elke waarde van de experimentele variabele (concentratie) met vaste variante. In dat geval zou de QQ-plot van de residuen een rechte lijn moeten laten zien, wat grofweg zo is. Ook zouden de punten in de residuenplot een band moeten vormen met ongeveer constante breedte. Dat is ook het geval. Er lijkt dus aan de voorwaarden te zijn voldaan.

d) Lees af: $R^2 = 0{,}9931$. Dat betekent dat maarliefst 99,3% van de variantie in de absorptie kan worden toegeschreven aan / verklaard door variatie in de eiwitconcentratie.

Opgave 8:

a) Dat betekent dat er een positief verband is tussen de twee variabelen.

b) Ja, dan is er een significant verband tussen X en Y.

c) Nee, dat is waarschijnlijk niet erg effectief. Het lijkt waarschijnlijk dat het verband tussen X en Y geen direct causaal (oorzakelijk) verband is: het eten van hamburgers veroorzaakt waarschijnlijk geen inbraken. Ook ligt de causaliteit waarschijnlijk niet andersom: inbraken zijn waarschijnlijk niet de oorzaak van een hoge hamburgerconsumptie. Het meest voor de hand liggend is de verklaring dat beide factoren een *gemeenschappelijke oorzaak* hebben. Zowel een hoge consumptie van *fast food* als criminaliteit zijn mogelijk geassocieerd met sociaal-economische status.

Opgave 9: Daar wordt mee bedoeld: dat er een correlatie is tussen X en Y wil nog niet zeggen dat X een direct causaal effect heeft op Y (of andersom). In opgave 8 is dat duidelijk geïllustreerd. Maar hoe kun je een causaal verband dan wel aantonen?

Op filosofisch niveau kun je hier lang over praten. Wat is eigenlijk een oorzakelijk verband? Wanneer zeggen we eigenlijk dat A de oorzaak is van B, en hoe weten we dat? Is het voldoende dat B altijd optreedt na A? Hoe onderscheidt dat zich van correlatie? Het probleem houdt intiem verband met het inductieprobleem; later dit jaar zul je hier meer over leren, bij Wetenschapsfilosofie.

Filosofische bespiegelingen daargelaten, kunnen een omgekeerde causaliteit (Y veroorzaakt X) en een gemeenschappelijke oorzaak (Z veroorzaakt zowel X als Y) in de praktijk worden uitgesloten door middel van een experimentele onderzoeksopzet (in tegenstelling tot een observationele onderzoeksopzet). Als wij zelf de waarde van X kiezen en manipuleren, dan kunnen we er zeker van zijn dat noch Y noch een onbekende Z invloed hebben op X. Als er vervolgens een significante correlatie wordt gevonden tussen X en Y, dan kunnen we die wel toeschrijven aan een causaal effect van X op Y.

Opgave 10:

a) Ja: bij het voorspellen van Y is X alleen informatief als er een verband is tussen X en Y. Een regressieanalyse vereist bovendien dat het verband *lineair* is. Daar volgt uit dat er ook een correlatie moet zijn.

b) Nee, dit is niet noodzakelijk. Je kunt Y ook voorspellen uit X als er door een andere reden een lineaire relatie is tussen die twee.

Opgave 11:

a) Een lineaireregressieanalyse is alleen van toepassing als er een lineaire relatie is tussen X en Y. Dat is voor 1-weg ANOVA niet nodig. Bovendien moet X voor regressie een numerieke variabele zijn; dat is voor 1-weg ANOVA niet nodig. Andersom gebruik je 1-weg ANOVA alleen als de waarden van X uiteenvallen in groepen. Voor regressie hoeven geen groepen gedefinieerd te zijn.

b) Stel je voor dat er wel sprake is van groepen, maar dat die groepen gekenmerkt worden door numerieke waarden van variabele X. (Dit is het geval in het huidige voorbeeld: de groepen worden gekenmerkt door het aantal genotypes.) Wanneer je alleen wilt testen of de gemiddelden van de groepen gelijk zijn, dan kun je altijd 1-weg ANOVA toepassen. Als je bovendien een lineair verband vermoedt, dan kun je regressie toepassen.

c) Als het er op lijkt dat er een lineair verband bestaat tussen het aantal spruiten en het aantal genotypes, dan kun je een regressieanalyse toepassen. Een plot van de gegevens laat zien dat zo'n verband er best kan zijn. Maar op basis van slechts drie groepen (X-waarden) is dat zeer speculatief. 1-weg ANOVA lijkt meer voor de hand te liggen.

Opgave 12:

a) H_0 : De helling van de regressielijn is gelijk aan 0 ($\beta = 0$).
H_A : De helling van de regressielijn is ongelijk aan nul ($\beta \neq 0$).

b) i) Lineair verband: Aan het spreidingsdiagram is te zien dat er een positieve relatie lijkt te zijn. Deze relatie kan lineair zijn, al liggen de punten bij tijdstip 8 uur aan de lage kant. De residuenplot geeft hetzelfde beeld. ii) Normale verdeling van de residuen met gelijke variantie voor iedere waarde van de experimentele variabele: De residuen zijn redelijk normaal verdeel, zoals te zien is aan de boxplot van de residuen en de Q–Q-plot van de residuen (onder `plot(resultaat)`. Aan de residuenplot is bovendien te zien dat de variantie op de verschillende tijdstippen vergelijkbaar is. Je kunt de standaardafwijkingen op de vier tijdstippen ook direct vergelijken: ze liggen tussen 0,37 en 0,53, en dat verschil is volgens Levenes

toets absoluut niet significant ($P = 0{,}97$). We concluderen dat er aan de aannames is voldaan.

c) Uit de ANOVA-tabel kan de overschrijdingskans worden afgelezen: $P = 1{,}68 \times 10^{-7} < \alpha$. De helling verschilt dus significant van 0.

d) Het kwadraat van de correlatiecoëfficiënt r is gelijk aan R^2. We lezen R^2 af en vinden $R^2 = 0.6298 = r^2$. Dan is $r = \sqrt{r^2} = 0{,}7936$ of $r = -\sqrt{r^2} = -0{,}7936$. Maar aangezien het een stijgend verband betreft, moet r positief zijn en dus $r = 0{,}7936$.

e) De regressielijn heeft de vorm $Y_i = a + bX_i$. We kunnen a aflezen uit de uitvoer van de `summary()` funcie: $a = 2,88458$. Maar de waarde van b is gemaskeerd door xxxxxxx en zal dus berekend moeten worden. Om deze te berekenen maken we gebruik van de volgende formule die op college is behandeld:

$$b = r(s_Y/s_X).$$

De standaardafwijkingen $s_Y = 0,7476$ en $s_X = 2,877$ uur zijn gegeven in de beschrijvende statistiek, en r was hiervoor al afgelezen; zo vinden we direct dat $b = 0,206$/uur.

Een andere optie: we weten dat $\bar{Y} = a + b\bar{X}$. Omdat a, $\bar{Y}$, en $\bar{X}$ gegeven zijn (zie beschrijvende statistiek), kan hieruit b worden afgeleid; weer volgt $b = 0,206$/uur.

De regressielijn wordt dus:

$$\hat{Y} = 2,885 + (0,206/\text{uur}) \times X.$$

f) Invullen van $X = 5$ in de formule voor de regressielijn levert op: $\hat{Y} = 3{,}916$. (Zorg dat je de co'effici'enten a en b niet tussentijds afrondt.)

Week 5

Opgave 1:

a) Hier is de populatiestandaardafwijking σ gegeven; we gebruiken dus niet de t-verdeling maar de standaardnormale verdeling om het betrouwbaarheidsinterval uit te rekenen. We vinden:

$$\mu = 36 \pm 1{,}96 \times 3{,}5/\sqrt{5} = 36 \pm 3{,}1 \text{ MU}.$$

b) Als het betrouwbaarheidsinterval niet breder mag zijn dan 4 MU, dan zoeken we dus de kleinste waarde van n zodanig dat $1{,}96 \times 3{,}5/\sqrt{n} \leq 2$ MU. Oplossen levert $n \geq 11{,}8$. We hebben dus $n = 12$ waarnemingen nodig om de gewenste precisie te bereiken.

c) We passen de vergelijking in het vorige onderdeel aan tot:

$$1{,}96 \times 3{,}5/\sqrt{n} \leq \delta.$$

Oplossen voor n levert meteen de gevraagde formule op.

De formule in W&S is

$$n \approx 4\left(\frac{\sigma}{\text{uncertainty}}\right)^2.$$

De "uncertainty" in deze formule hebben wij δ genoemd. Het enige verschil is dat de vuistregel uit *W&S* een factor 4 heeft staan waar in onze formule $(1{,}96)^2 = 3{,}84$ staat. Omwille van de eenvoud is die factor dus in W&S afgerond naar 4. Soortgelijke afrondingen liggen ten grondslag aan de andere formules in W&S voor het berekenen van de benodigde steekproefgrootte.

d) Zoals de formule laat zien, hangt n af van het *kwadraat* van δ. Dus, als we een *twee* keer zo kleine δ wensen, dan hebben we een *vier* keer zo grote n nodig. Zo komen we op tenminste $4 \times 11{,}8 = 47{,}2$ waarnemingen. We kiezen $n = 48$.

e) Als we de precisie 10 keer willen vergroten (dus δ tien keer kleiner), dan hebben we een $10^2 = 100$ keer grotere steekproef nodig. Je ziet: dit loopt al snel uit de hand! Het is dus intrinsiek lastig om een heel grote precisie te bereiken!

Opgave 3:

a) Hoe groter de steekproeven, hoe groter het onderscheidingsvermogen. De eerste studie heeft dus een groter onderscheidingsvermogen.

b) Hoe groter de variantie in de groepen, hoe kleiner het onderscheidingsvermogen. De laatste studie heeft dus een groter onderscheidingsvermogen.

c) Een groter effect is gemakkelijker aan te tonen. Het onderscheidingsvermogen is dus groter in de eerste studie.

d) Een groter effect is gemakkelijker aan te tonen. Je kunt dan dus met een kleinere steekproef toe. Het aantal patiënten zal dus het grootst moeten zijn in de tweede studie.

Opgave 4: Antwoord op opgave 14.18 (2e editie) of 14.19 (3e editie) uit W&S:

Een steekproef van 81 vogels zou voldoende moeten zijn. Dit is een gepaarde toets, dus je gebruikt de formule voor de steekproefgrootte die hoort bij de gepaarde t-toets

(zie Quick Formula Summary van hoofdstuk 14 in W&S). Dan krijg je $n = 8 \times (0{,}159/0{,}05)^2 = 80{,}9$, dus afgerond 81.

Opgave 5: a.

Opgave 6:

a) Het grote probleem met deze proefopzet is dat er geen controlegroep is. Daardoor kun je niet controleren of een eventueel verschil het gevolg is van een placebo-effect. Bovendien: omdat we mannen hebben geselecteerd die bij meting 1 een ongewoon hoge bloeddruk hadden, verwachten we *regression to the mean* (zie W&S). De bloeddruk van ieder mens schommelt afhankelijk van allerlei factoren (voeding, stress, temperatuur, ...). We zullen dus zeker ook mannen selecteren die toevallig op die dag een hogere bloeddruk hadden dan normaal. De bloeddruk van een groot deel van deze mannen zal ook zonder interventie naar normale waarden terugkeren. Dat bij meting 2 de getallen lager uitvallen kan dus heel goed puur en alleen veroorzaakt zijn door *regression to the mean.*

   Het belangrijkst is dat je een opzet voorstelt met een controlegroep. Daarnaast moet de statistische toets die wordt voorgesteld wel stroken met de onderzoeksopzet. Een eenvoudige mogelijkheid is om na meting 1 de mannen met een hoge bloeddruk willekeurig te verdelen over twee groepen. De ene groep wordt behandeld met het medicijn, de andere groep krijgt exact dezelfde behandeling, maar met een placebo. De behandelingen worden dubbel-blind uitgevoerd. Als het medicijn werkt, dan zou dat moeten leiden tot een verschil in de gemiddelde bloeddrukverlaging tussen deze twee groepen. Om dat te toetsen is een t-toets voor twee onafhankelijke steekproeven geschikt.

   Overigens verwacht je dan dat bij meting 2 het gemiddelde omlaag is gegaan bij zowel de behandelde groep als de placebogroep. Het is dan verleidelijk om te concluderen dat er een sterk placebo-effect is gevonden. Maar dat hoeft helemaal niet de juiste verklaring te zijn! Het is heel goed mogelijk dat de placebo-behandeling helemaal geen effect heeft, maar de bloeddruk in die groep toch omlaag is gegaan door *regression-to-the-mean.* Wees hierop bedacht als mensen claimen dat ze een sterk placebo-effect hebben gemeten: vaak is *regression-to-the-mean* een veel betere verklaring voor het gemeten effect.

b) De gebruikte formule moet passen bij de toets die in het vorige onderdeel werd voorgesteld, en er moet een onderbouwde keuze worden gemaakt voor σ en D. Voor bovenstaande t-toets voor twee onafhankelijke steekproeven is op basis van de beschrijvende statistiek $\sigma = 10$ mm Hg een redelijke keuze (de standaardafwijking van het verschil was in bovenstaand experiment immers 8,5 mm Hg). Een effect kleiner dan 5 mm Hg zal waarschijnlijk voor medische toepassingen weinig interessant zijn; we vinden het dus niet nodig om een effect kleiner dan dat te kunnen aantonen. Het is dus redelijk om $D = 5$ mm Hg te kiezen. Invullen in de formule levert dan op:

$$n \geq 16 \times \left(\frac{10}{5}\right)^2 = 64.$$

Deel II

Computerpractica

Computerpracticum 1: Beschrijvende statistiek & *t*-toetsen

Voorbereiding

- Als je met SolisWorkspace wilt werken, controleer dan dat je toegang hebt tot je account.
- Als je op je eigen laptop wilt werken, controleer dan dat R en RStudio werken en up-to-date zijn.

Onderwerpen

beschrijvende statistiek • *t*-toetsen • aannames *t*-toetsen • Q–Q-plots • Levenes toets • transformaties

Methodes in R die van pas zullen komen

```
> mijndataframe <- read.csv("/path/to/file.csv") # lees een csv–bestand in als dataframe met
    naam "mijndataframe".
> mijndataframe <- data.frame(kolom1, kolom2) # creert een dataframe "mijndataframe" met
    kolommen gevormd door vectoren "kolom1" en "kolom2".
> summary(mijndataframe) # geeft verschillende kengetallen (gemiddelde, mediaan, etc.) voor de
    kolommen van de dataframe met naam "mijndataframe".
```

```
> qqnorm(mijnvector); qqline(mijnvector) # produceert een Q–Q–plot van de gegevens in vector "
    mijnvector".
```

```
> by(mijnvector, mijnfactor, mijnfunctie) # past de functie "mijnfunctie" toe op de gegevens in "
    mijnvector", uitgesplitst naar de levels in "mijnfactor".
```

```
# t–toets voor twee onafhankelijke steekproeven:
> t.test(mijnvector1, mijnvector2, var.equal = TRUE) # "mijnvector1" en "mijnvector2" zijn
    vectoren met daarin respectievelijk steekproef 1 en 2.
> t.test(y ~ X, data = mijndata, var.equal = TRUE) # "mijnmydata" is een data frame met
    kolommen "y" en "X", waarbij y een numerieke vector is met meetwaarden, en X een factor die de groepen
     specificeert.
```

```
# t–toets voor twee gepaarde steekproeven:
> t.test(mijnvector1, mijnvector2, paired = TRUE) # "mijnvector1" en "mijnvector2" zijn
    vectoren met daarin respectievelijk steekproef 1 en 2. R neemt aan dat de gegevens op volgorde staan,
    zodat het eerste element uit vector1 een paar vormt met het eerste element uit vector2, etc.
> t.test(y ~ X, data = mijndata, paired = TRUE) # "mijndata" is een dataframe met kolommen
    y en X, waarbij y een numerieke vector is met meetwaarden, en X een factor die de groepen specificeert. R
    neemt aan dat de gegevens op volgorde staan, zodat het eerste element uit groep 1 een paar vormt met het
     eerste element uit groep 2, etc.
```

```
> library("car")
> leveneTest(y ~ X, data = mijndata) # voer Levenes toets uit. "mijndata" is een dataframe met
    kolommen y en X, waarbij y een numerieke vector is met meetwaarden, en X een factor die de groepen
    specificeert.
```

Opgaven

Voor je begint:

- Start RStudio.
- Open binnen RStudio een nieuw leeg script (*File* ►*New file* ►*R script*).
- Sla het script op, op een logische plek, met een logische naam (e.g. "`cp1.R`").
- Bij het maken van onderstaande opgaven schrijf je je code steeds in dit nieuwe bestand. Om een regel code uit te voeren, ga je op de betreffende regel staan en drukt [Ctr][Enter] in. De betreffende regel wordt dan naar het Console gestuurd en uitgevoerd.
- Het resultaat van dit computerpracticum moet een lijst met commando's zijn waarmee je alle resultaten kunt produceren.
- Schrijf je antwoorden op vragen en ander commentaar bij de regels van het script door gebruik te maken van het #-teken.

■ **Opgave 1.** In de file "kurk.csv" (te vinden op Blackboard) is van 28 bomen het gewicht aan kurkafzetting (in centigrammen) aan de oost- en aan de westzijde van de boom gegeven. De onderzoekers willen weten of aan beide zijden van de bomen evenveel kurk wordt afgezet.

a) Download het bestand van Blackboard en lees het in als dataframe met naam `kurk`. (Gebruik de functie `read.csv()`.)

b) Bestudeer altijd eerst de structuur van het dataframe. (Gebruik `str(kurk)` en eventueel `head(kurk)` of `View(kurk)`.) Hoeveel kolommen heeft het dataframe? Hoeveel regels zijn er? Van welk datatype is iedere kolom, en is dat juist?

c) Voordat je een analyses of toetsen gaat uitvoeren, is het belangrijk om de data eerst eens goed te bekijken. Maak daarom een boxplot voor de waarden van kolommen `OOST` en `WEST` en bestudeer ze. Maak ook histogrammen voor beide kolommen. Beschrijf de verdelingen in woorden. Zijn de verdelingen symmetrisch of scheef? Zijn ze bel-vormig? Zijn er uitbijters? Zie je verschillen tussen oost een west?

d) Bereken kengetallen (gemiddelde, mediaan, standaardafwijking, etc.) voor `OOST` en `WEST`. (Het is handig om onder andere de functie `summary()` te gebruiken.) Vallen je dingen op? Zijn er opvallende verschillen in ligging en spreiding tussen oost en west?

e) Welke toets gebruik je om deze gegevens te analyseren en een antwoord te vinden op de vraag van de onderzoekers? Beargumenteer je antwoord.

f) Wat zijn de nulhypothese en de alternatieve hypothese die bij de toets horen?

g) Welke aannames zou je moeten maken om deze toets te mogen uitvoeren? Maak plotjes om te zien of die aannames redelijk zijn voor deze gegevens. (Zie boven hoe je Q–Q-plots moet maken.)

h) Voer de onder e) gekozen toets uit en trek je conclusies ten aanzien van de hypotheses gesteld in f).

i) Geef het 95%-betrouwbaarheidsinterval voor het verschil in afzetting tussen beide zijden.

■ **Opgave 2.** Een lijn fruitvliegjes is gekweekt op zijn resistentie tegen DDT. De vruchtbaarheid (uitgedrukt in het aantal eitjes dat een vrouwtje legt per dag over een periode van 14 dagen) van een groep van 25 vrouwtjes uit deze lijn wordt vergeleken met die van een groep van 25 controlevrouwtjes die niet speciaal gekweekt zijn. De vruchtbaarheidswaarden van deze twee lijnen vind je in het bestand "fruitvlieg.csv" dat te vinden is op Blackboard. We willen weten of de resistente vrouwtjes van de controlegroep verschilt in termen van vruchtbaarheid.

a) Download het bestand van Blackboard en lees het in als een dataframe.

b) Bestudeer de structuur van het dataframe. (Welke variabelen zijn er? Wat is hun type volgens R, en klopt dat? Hoeveel regels zijn er? Begrijp je hoe de data zijn gestructureerd?)

c) Bekijk de data eens goed. Maak boxplots en histogrammen en bestudeer ze. Beschrijf de verdelingen. (Symmetrisch, scheef, unimodaal, bimodaal?) Vallen je dingen op? Wat is je beeld van het verschil tussen de groepen?

d) Bereken kengetallen (gemiddelde, mediaan, standaardafwijking, etc.) voor de steekproeven. Bestudeer de uitkomsten. Vallen je dingen op? Zie je opvallende verschillen tussen de groepen? Lijkt er een verschil te zijn in vruchtbaarheid, en zo ja, welke lijn lijkt een hogere vruchtbaarheid te hebben?

e) Welke toets gebruik je om deze gegevens te analyseren en een antwoord te vinden op de vraag van de onderzoekers? Beargumenteer je antwoord.

f) Wat zijn de nulhypothese en de alternatieve hypothese die bij de toets horen?

g) Welke aannames zou je moeten maken om deze toets te mogen uitvoeren? Analyseer de gegevens om te zien of die aannames in dit geval redelijk zijn. (Voer daartoe ook Levenes toets uit.)

h) Voer de onder e) gekozen toets uit en trek je conclusies ten aanzien van de hypotheses gesteld in f).

i) Vergelijk de vruchtbaarheid van beide lijnen met elkaar. Geef een 95%-betrouwbaarheidsinterval voor de effectgrootte (het verschil tussen de gemiddelde vruchtbaarheid van beide lijnen).

■ **Opgave 3.** Om het stimulerende effect van cafeïne te onderzoeken is een dubbelblind experiment opgezet. Twintig mannelijke studenten

werden getraind in het regelmatig tikken met een vinger op tafel. Vervolgens werden ze aselect in twee groepen verdeeld. De ene groep kreeg een vloeistof zonder cafeïne te drinken, de andere groep een vloeistof mét cafeïne. Twee uur na het drinken van de vloeistof werd iedere proefpersoon gevraagd met zijn vinger op tafel te tikken. Het aantal tikken per minuut is geregistreerd (zie Tabel 1.11). De onderzoekers vragen zich af of er een verschil is in de gemiddelde tikfrequentie tussen de twee groepen.

Tabel 1.11: Lijst van waargenomen tik-frequenties met en zonder cafeïne-consumptie.

frequentie (1/min)	
0 ml cafeïne	200 ml cafeïne
242	246
245	248
244	250
248	252
247	248
248	250
242	246
244	248
246	245
242	250

a) Welke toets zou je willen uitvoeren gezien de onderzoeksvraag?

b) Creëer zelf een dataframe op basis van Tabel 1.11. Gebruik daarbij dezelfde structuur de dataframe van opgave 2 (een zogenaamde "long-form" tabel).

c) Zoals bij de vorige opgaven: Bekijk de gegevens eerst eens door verschillende plotjes te maken en kengetallen uit te rekenen. Bestudeer de uitvoer om je een beeld te vormen van de gegevens.

d) Welke aannames moet je doen om de toets te mogen uitvoeren? Onderzoek of de aannames gerechtvaardigd zijn voor deze gegevens.

e) Voer de toets uit (ervan uit gaande dat aan de voorwaarden is voldaan) en beantwoord de vraag of cafeïne deze taak beïnvloedt.

f) Geef een schatting van de grootte van het effect met een 95%-betrouwbaarheidsinterval.

g) Bespreek de grootte van het effect. Is het effect statistisch significant? Is het effect relevant?

Computerpracticum 2:
ANOVA, correlatie & regressie

Onderwerpen

ANOVA • correlatie & regressie

Methodes in R die van pas zullen komen

```
# ANOVA:
> resultaat <- lm(y ~ X, data = mijndataframe) # voert een ANOVA uit op dataframe "
    mijndataframe", waarbij y de numerieke responsvariabele is, en X een factor die de groepen specificeert.
    Het resultaat wordt opgeslagen in een lijst "resultaat" voor verdere verwerking.

# Lineaire regressie:
> resultaat <- lm(y ~ x, data = mijndataframe) # voert een lineaire regressie uit op dataframe "
    mijndataframe", waarbij x en y beide numerieke variabelen zijn. Het resultaat wordt opgeslagen in een
    lijst "resultaat" voor verdere verwerking.

# Zowel ANOVA als lineaire regressie:
> anova(resultaat) # geeft de ANOVA tabel die hoort bij "resultaat"
> summary(resultaat) # geeft een tabel met schattingen voor de verschillen tussen de gemiddelden van
    iedere groep met een referentiegroep. Als referentiegroep wordt de eerste level van de factor X genomen.
> resultaat$residuals # geeft de residuen van het lineaire model.
> confint(resultaat) # geeft betrouwbaarheidsintervallen voor de coefficienten van het model
> plot(resultaat) # genereer nuttige plots die je helpen beoordelen of aan de aannames is voldaan.
```

Opgaven

Voor je begint:

- Open binnen RStudio een nieuw leeg script.
- Sla het script op, op een logische plek, met een logische naam (e.g. "`cp2.R`").
- Bij het maken van onderstaande opgaven schrijf je je code steeds in dit nieuwe bestand. Het resultaat van dit computerpracticum moet een lijst met commando's zijn waarmee je alle resultaten kunt produceren.
- Schrijf je antwoorden op vragen en ander commentaar bij de regels van het script door gebruik te maken van het #-teken.

■ **Opgave 1.** Kunnen huisdieren de effecten van stress verminderen bij hun baasjes? Vijfenveertig vrouwen (die naar eigen zeggen van honden houden) zijn willekeurig ingedeeld in drie groepen:

1. stressvolle taak alleen (controle);
2. stressvolle taak in aanwezigheid van een goede vriend(in);
3. stressvolle taak in aanwezigheid van een hond.

De gemiddelde hartfrequentie tijdens de taak is gemeten. De gegevens staan in het bestand "honden.csv".

Zijn er verschillen tussen de drie condities?

a) Download het bestand en laad het in een dataframe met de naam `honden`.

b) Bestudeer de dataframe. De kolom `group` zou een factor moeten zijn. Welke levels heeft deze factor? Visualiseer, beschrijf en bestudeer de data.

c) Toets of er een verschil is in gemiddelde hartfrequentie tussen de 3 groepen met behulp van ANOVA. Gebruik daarvoor de `lm()` functie en de `anova()` functie.

d) Wat zijn de aannames die je moet doen om ANOVA te mogen uitvoeren? Controleer of die aannames redelijk zijn voor deze gegevens. Bekijk daartoe onder andere de boxplots, beoordeel een Q–Q-plot van de residuen, vergelijk de standaarddeviaties, en voer Levenes toets uit.
Tip: als je het resultaat van de ANOVA opslaat in een variabele,

```
> resultaat <- lm(rate ~ group, data = honden)
```

dan is `resultaat$residuals` een vector met de residuen. Bovendien geeft

```
> plot(resultaat)
```

je dan direct vier plots die je kunnen helpen de aannames te controleren.

e) Als je in onderdeel c) hebt gevonden dat de gemiddelden van de groepen niet gelijk zijn , wil je ook weten welke groepen van elkaar verschillen, en hoeveel. Gebruik daartoe de `summary()` functie. Pas een Bonferroni-correctie toe. Is na deze correctie het verschil tussen `Friend` en `Control` significant? En het verschil tussen `Pet` en `Control`? En het verschil tussen `Pet` en `Friend`? Hoe groot schat je de verschillen?

Tip: De functie `summary()` geeft alleen schattingen voor de verschillen tussen iedere groep en een *reference group*. Als *reference group* wordt automatisch de eerste level van `honden$group` genomen (de *reference level*). Als je een andere groep als controlegroep wilt gebruiken, dan zul je een andere level van de factor `honden$group` op de eerste plek moeten zetten. Dit kan met de functie `relevel()`. Bijvoorbeeld,

```
> honden$group <- relevel(honden$group, ref = "Pet")
```

maakt van `Pet` de *reference level*.

f) Schrijf een korte samenvatting van de resultaten van dit onderzoek.

■ **Opgave 2.** In Behaviour 123 (1992) pp. 77–83 beschrijven twee onderzoekers de mogelijke relatie tussen het aantal inwoners van grote

steden en de gemiddelde loopsnelheid van de inwoners van die steden. Een aantal resultaten van hun onderzoek is vastgelegd in het bestand "loopsnelheid.csv".

a) Download het bestand, en lees het in als een dataframe. Bestudeer de dataframe.

b) Visualiseer, beschrijf en bestudeer de gegevens.

c) Maak daarbij ook een spreidingsdiagram van de gemiddelde loopsnelheid (`av.wlksp`) versus de logaritme van het aantal inwoners van de stad (`popsize`). (Voeg de logaritme van het aantal inwoners als een nieuwe variabele (`logpops`) aan de dataframe toe.)

   Beschrijf de samenhang tussen deze twee variabelen.

d) Bereken de correlatiecoëfficiënt bij het spreidingsdiagram uit onderdeel c). (Gebruik de functie `cor.test()`.)

e) Welke aannames moet je doen om te toetsen of deze correlatiecoëfficiënt significant van 0 verschilt? Is die aanname hier redelijk?

f) Aangenomen dat aan de aannames is voldaan: Is de correlatiecoëfficiënt statistisch significant verschillend van nul?

g) Stel de vergelijking op voor de regressielijn die de relatie tussen de twee variabelen beschrijft. (Gebruik `lm()` en `summary()`.) Wat zijn de aannames van de regressie-analyse, en zijn die hier redelijk?

h) Is er sprake van een significante regressie en waar leid je dit uit af?

i) Had je de correlatiecoëfficiënt ook uit de uitvoer van de regressieanalyse kunnen aflezen?

j) Welke methode (correlatie of regressie) heeft jouw voorkeur in het beantwoorden van de onderzoeksvraag? Beargumenteer je antwoord.